

# 子空间分析方法

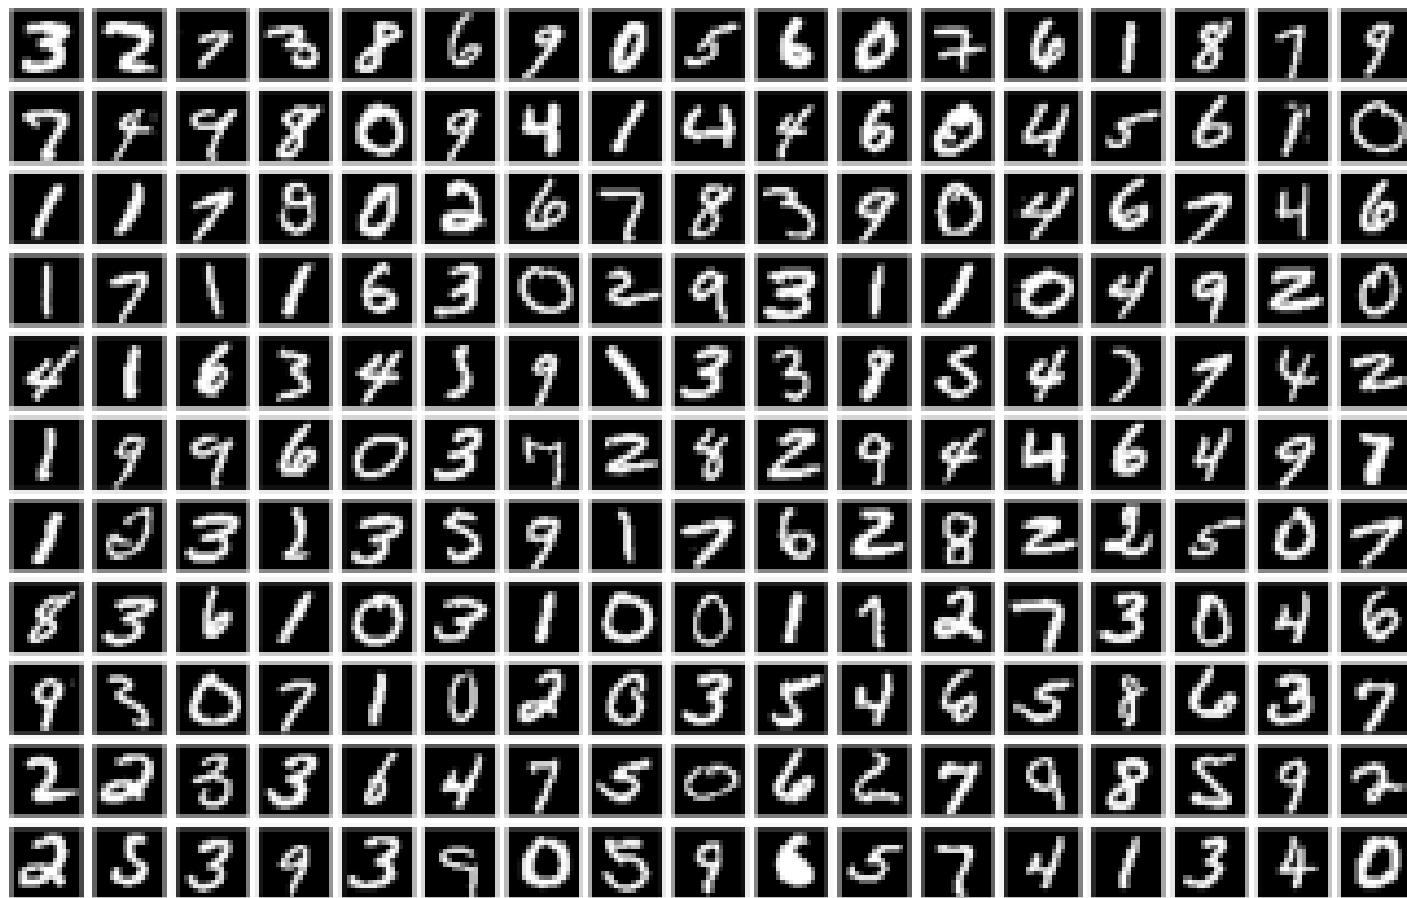
董秋雷

中国科学院自动化研究所

qldong@nlpr.ia.ac.cn

# 问题

- 下面的数字都是多少？



# 进一步的问题

- 怎样处理大数据量、高维数、非结构化的数据呢？
  - 直接在高维数据上处理；
  - 降维后再对低维数据进行处理；
  - 升到更高维度上再进行处理；

# 进一步的问题

- 直接在高维数据上处理：
  - 维数灾难 (Curse of Dimensionality)：满足一定统计指标(期望与方差)的模型(精度)，需要的样本数量将随着维数的增加，指数增长(或模型复杂程度，或模型表示长度指数增长)。
  - 特征和特征之间是冗余的、信息量是不一样的。

# 子空间分析

- 降维后再对低维数据进行处理：
- 子空间分析
  - 把高维空间中松散分布的样本，通过线性或非线性变换压缩到一个低维的子空间中，在低维的子空间中使样本的分布更紧凑、更有利子分类，同时使计算复杂度减少。

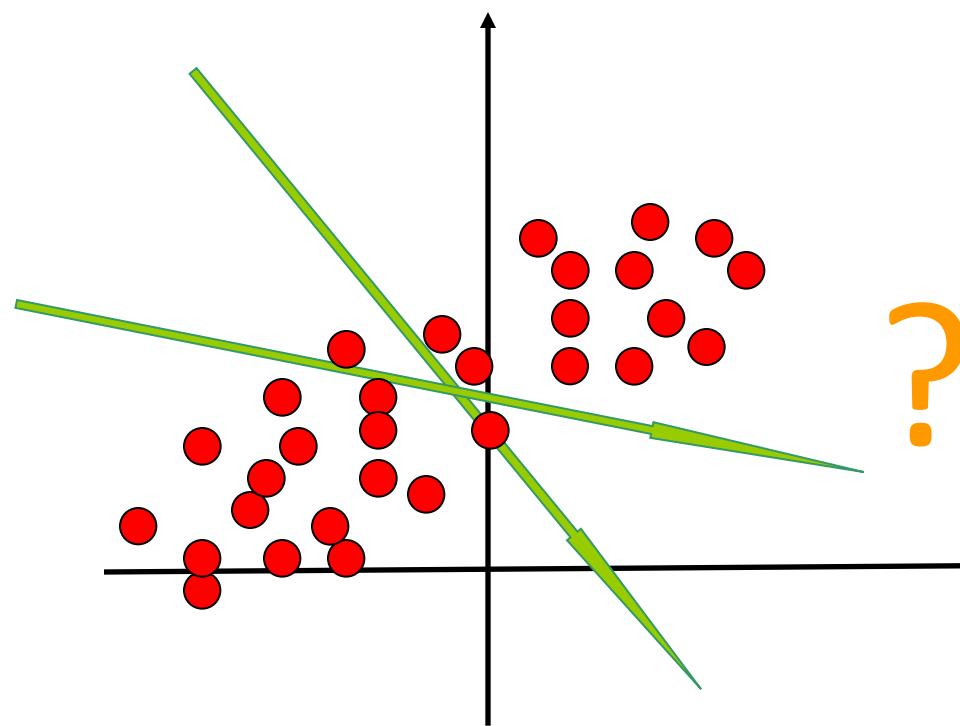
# 经典子空间分析算法

- 主成分分析方法 (Principal Component Analysis, PCA)
- 独立成分分析方法 (Independent Component Analysis, ICA)
- 线性判别分析方法 (Linear Discriminant Analysis, LDA)

# PCA

- PCA: Principal Component Analysis, 主成分分析。
- 又名: Karhunen–Loève (K–L) 变换
- 又名: Hotelling变换
- 基本思想:
  - 将多个变量通过线性变换以选出较少个重要变量，这些新变量尽可能保持原有的信息。
  - 换成数学表述为：寻找投影映射P，使得样本从N维降到m维 ( $m < N$ )，同时最小化平方误差。

# PCA



# PCA的发展历史

- Karl Pearson于1901提出；
- Harold Hotelling于1933年加以发展；
- Kari Karhunen和Michel Loève 提出Karhunen-Loève theorem；
- Turk和Pentland于1991年正式提出eigenface的概念。



# PCA

- 变量定义：
- 训练样本集： $X = [x_1, x_2, \dots, x_n]$ , 其中 $x_i$ 是 $N$ 维向量
- 样本均值： $\mu = \frac{1}{n} \sum_{i=1}^n x_i$
- 离散度矩阵： $S = \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$
- 投影后的低维数据： $y_i = P^T (x_i - \mu)$ , 其中 $P$ 是 $N \times m$ 维矩阵

# PCA的特性

- 怎样使新变量尽可能地保持原有的信息呢？
- 重构误差最小 (least squares reconstruction)

样本:  $X = [x_1, x_2, \dots, x_n]$

投影:  $y_i = P^T (x_i - \mu)$ , 其中  $P$  是  $N \times m$  维矩阵

样本重构:  $\hat{x}_i = Py_i$

重构误差:  $e = \sum_{i=1}^n \| (x_i - \mu) - \hat{x}_i \|^2$

# PCA

- 最小化重构误差，等价于如下优化问题：

$$P = \arg \max_P |P^T S P|$$

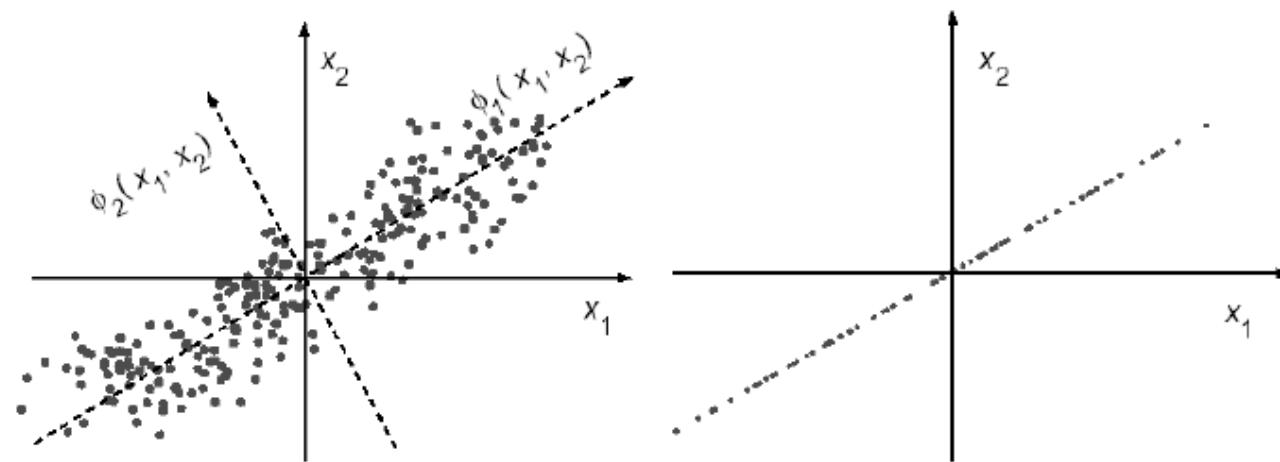
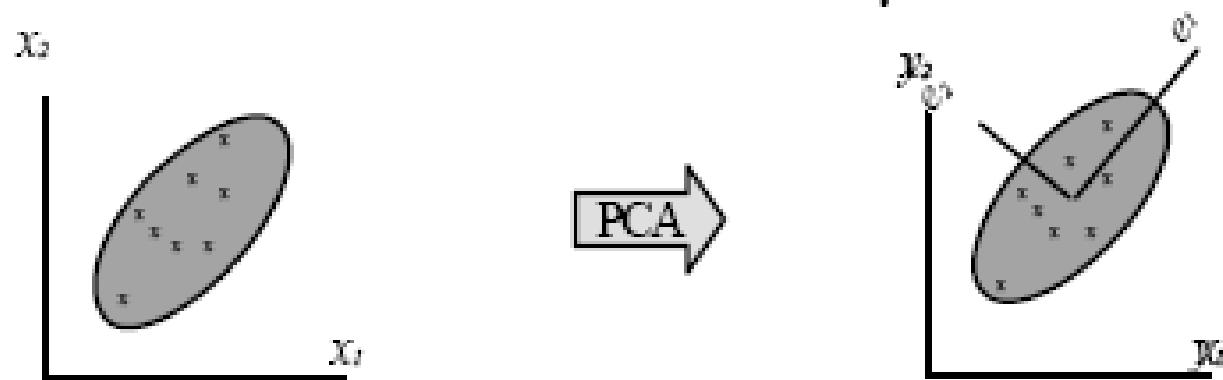
- 特征值分解： $S v_i = \lambda_i v_i, i = 1, 2, \dots, n$

其中  $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n$ ,  $\lambda_i$  与  $v_i$  分别是特征值和对应的特征向量

- 最大的一组特征值对应的特征向量组成的子空间即为所求：

$$P = [v_1, v_2, \dots, v_m]$$

# 二维情况的例子



# 计算步骤

- 对于给定的样本矩阵  $X = [x_1, x_2, \dots, x_n]$ , 其中  $x_i$  是  $N$  维向量
- 1. 计算样本均值  $\mu = \frac{1}{n} \sum_{i=1}^n x_i$
- 2. 计算离散度矩阵  $S = \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$
- 3. 将离散度矩阵进行特征值分解, 取最大的  $m$  个特征值和相应的特征向量  $P = [\nu_1, \nu_2, \dots, \nu_m]$ , 其中  $P$  是  $N \times m$  维矩阵。
- 4. 实现降维  $y_i = P^T (x_i - \mu)$

# PCA的应用

- 特征脸 (Eigenfaces)
  - Sirovich & Kirby 1987

“Low dimensional Procedure for the characterization of human faces” Journal of the Optical Society of America
  - Turk & Pentland 1991

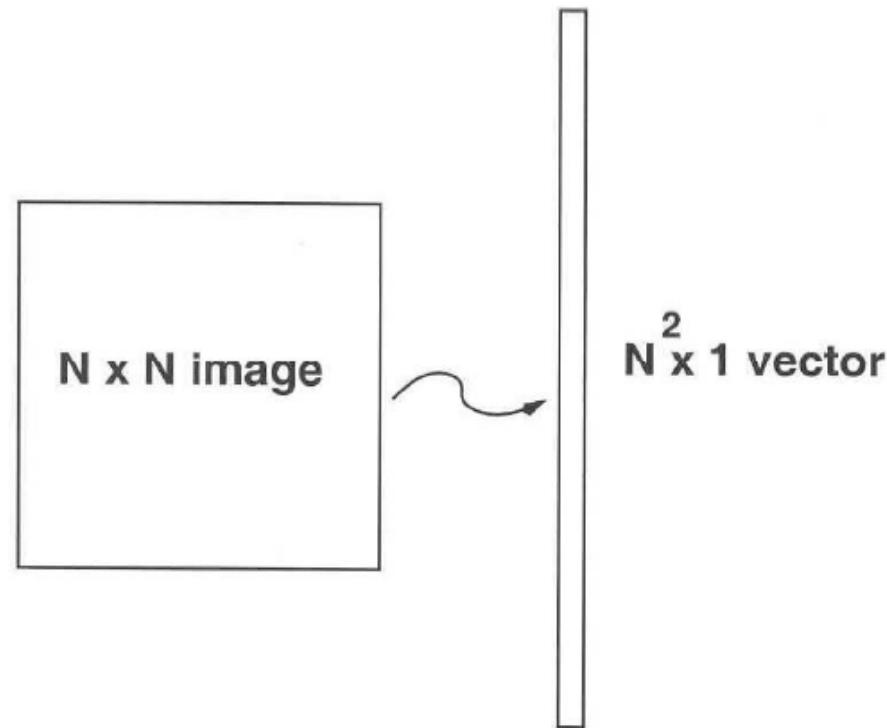
“Face recognition using Eigenfaces” IEEE Conference on Computer Vision and Pattern Recognition (CVPR)

# Eigenfaces



# Eigenfaces

- 人脸图像可以表示为一个向量

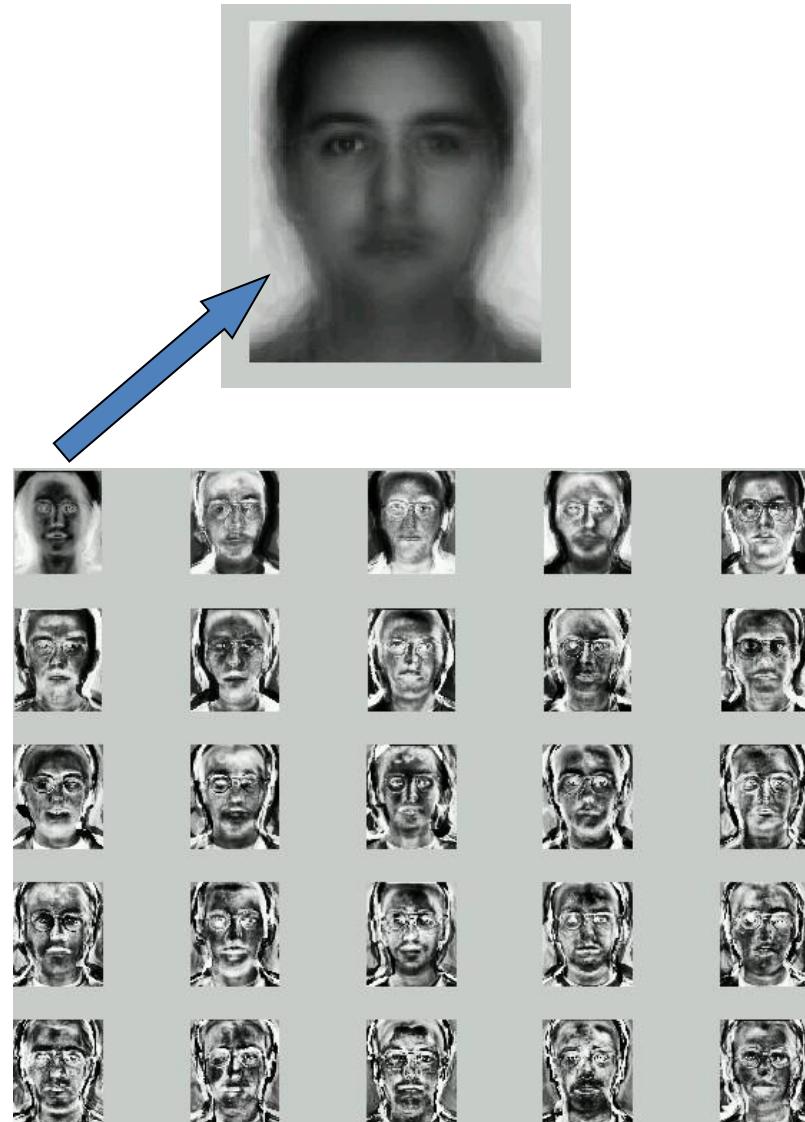
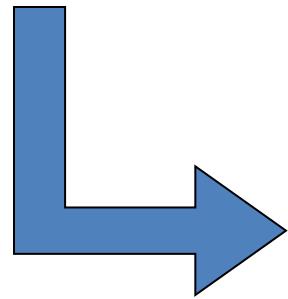


# Eigenfaces构建步骤

- 1. 给定训练图像矩阵  $X = [x_1, x_2, \dots, x_n]$ , 其中  $x_i$  表示一副训练图像。
- 2. 计算样本均值  $\mu = \frac{1}{n} \sum_{i=1}^n x_i$
- 3. 计算离散度矩阵  $S = \sum_{i=1}^n (x_i - \mu)(x_i - \mu)^T$
- 4. 将离散度矩阵进行特征值分解, 取最大的  $m$  个特征值和相应的特征向量  $P = [v_1, v_2, \dots, v_m]$ 。



原始人脸图像



特征脸 (Eigenface)

# 人脸表述与识别

- 人脸表述：基于得到的投影矩阵P，每张人脸可以由一个 $m$ 维向量表示

$$y_i = P^T (x_i - \mu)$$

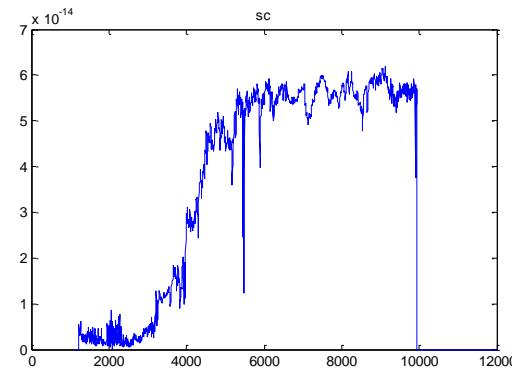
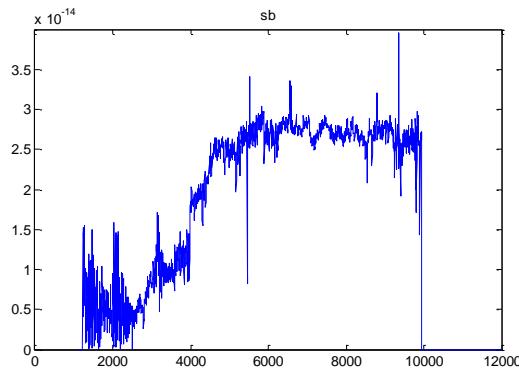
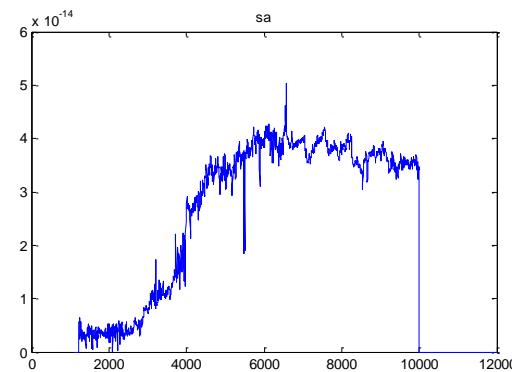
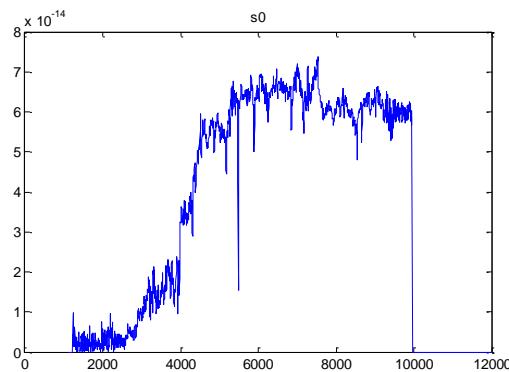
- 人脸识别：
  - 对于一张输入的人脸图像，计算它的低维表述

$$y_{input} = P^T (x_{input} - \mu)$$

- 计算  $k = \arg \min_i \|y_{input} - y_i\|$

# PCA在光谱方面的应用

- 四个正常星系的光谱维数为2726，横轴为波长，纵轴为流量



# PCA在光谱方面的应用

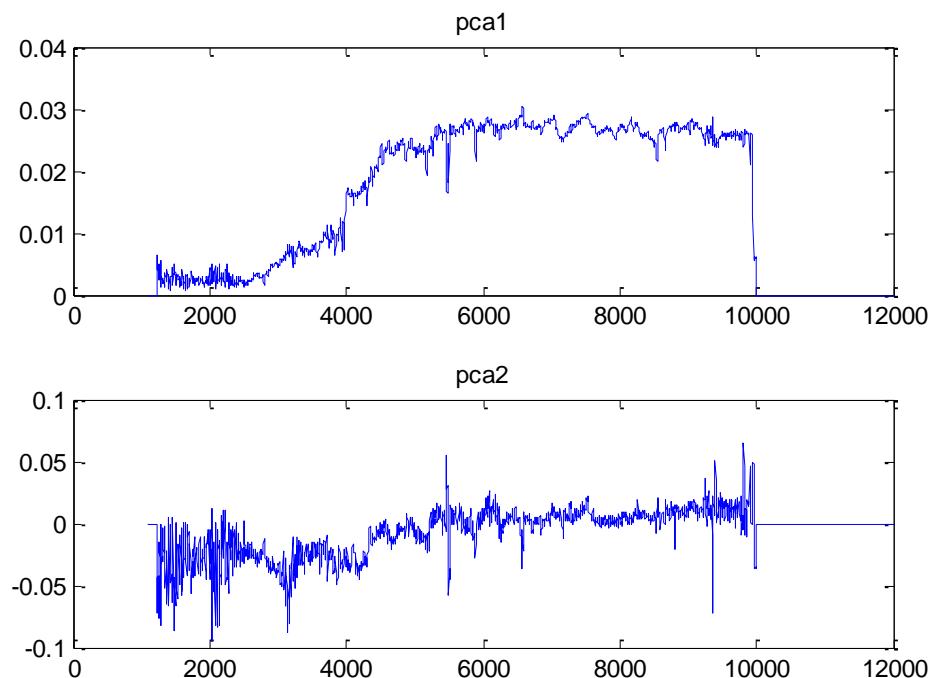
$$DD = \begin{bmatrix} 3.9737 & 0 & 0 & 0 \\ 0 & 0.0139 & 0 & 0 \\ 0 & 0 & 0.0092 & 0 \\ 0 & 0 & 0 & 0.0032 \end{bmatrix} \quad D = \begin{bmatrix} 3.9737 & 0 \\ 0 & 0.0139 \end{bmatrix}$$

特征值矩阵

方差贡献率大于0.995的  
两个特征值

# PCA在光谱方面的应用

- 投影基向量



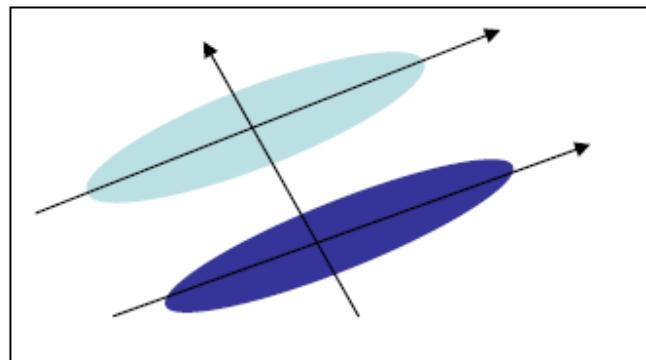
# PCA在光谱方面的应用

- 4个光谱向量的二维pca表示

$$spec = \begin{bmatrix} 0.9979 & 0.9968 & 0.9953 & 0.9968 \\ 0.0465 & -0.0206 & -0.0871 & 0.0611 \end{bmatrix}$$

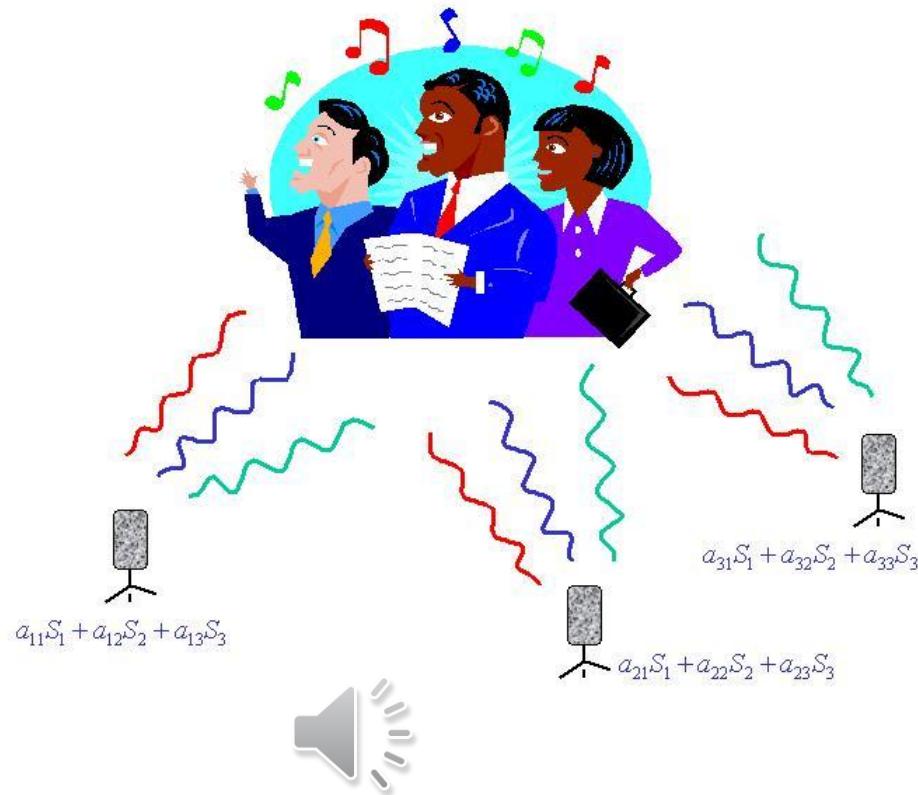
# PCA

- PCA对于椭球状分布的样本集有很好的效果，学习所得的主方向就是椭球的主轴.
- PCA 是一种非监督的算法，能找到很好代表所有样本的方向，但这个方向对于分类未必是最有利的。

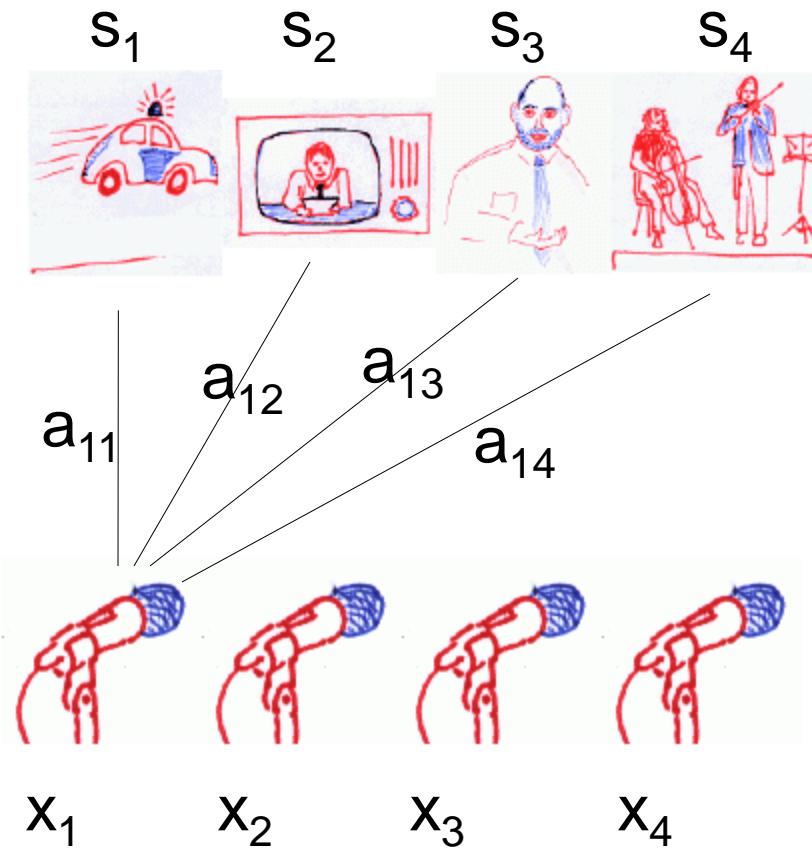


# ICA

- 20世纪80年代，盲信号分离（Blind Source Separation）：  
鸡尾酒会问题



# ICA



# ICA

- ICA, 独立成分分析: 指从多个源信号的线性混合信号中分离出源信号的技术。
  - ICA假设: 源信号统计独立。
  - 模型:  $x = A * s$  或  $x = \sum_{i=1}^n a_i s_i$
- 
- 求解:  $u = W * x = W * A * s$

# ICA发展历史

- 起源：20世纪80年代，盲信号分离（Blind Source Separation）  
例子：鸡尾酒会问题
- 正式提出：1994年，P. Comon  
“Independent Component Analysis --- a new concept?”  
Signal Processing
- 应用：1998年，Bartlett, et al 应用到人脸分析。

# 算法

- ❖ InfoMax 算法（信息极大化算法）：1995年，Bell & Sejnowski

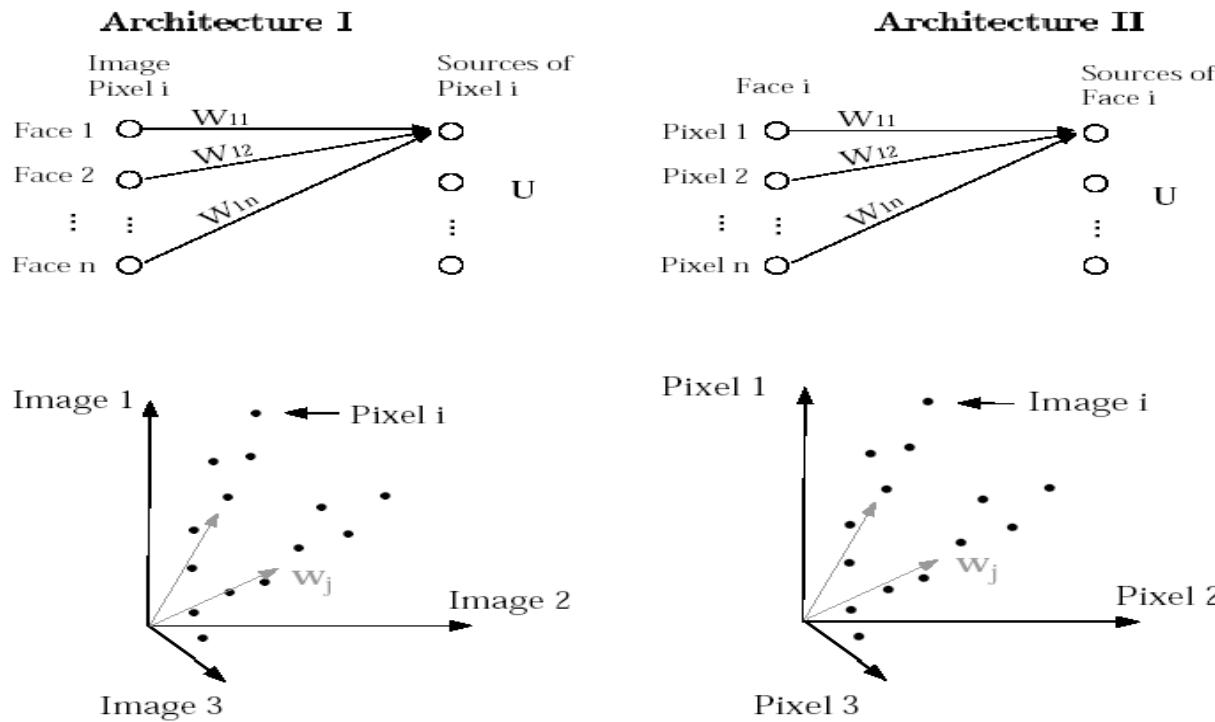
An information maximization approach to blind separation and blind deconvolution,  
Neural Computation

- ❖ FastICA 算法（固定点算法）：1997年，A. Hyvärinen & E. Oja

A fast fixed-point algorithm for independent component analysis.  
Neural Computation

# 人脸的ICA表示方法

- basis image (独立基图像)
- factorial code (因子表示)



# ICA在人脸识别中的应用

- 结构1：

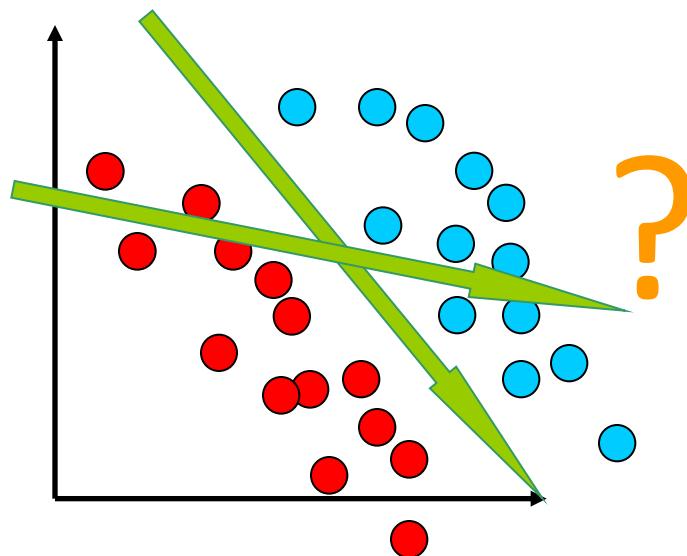
$$\text{face} = b_1 * \mathbf{u}_1 + b_2 * \mathbf{u}_2 + \dots + b_n * \mathbf{u}_n$$

- 结构2：

$$\text{face} = u_1 * \mathbf{a}_1 + u_2 * \mathbf{a}_2 + \dots + u_n * \mathbf{a}_n$$

# LDA

- 能否找到一个实现有效分类的投影方向呢？



# LDA

- LDA (Linear Discriminant Analysis) , 又称 Fisher Discriminant Analysis , 是一种监督的维数约简方法.
- Fisher判别原则：寻找投影W，使得投影后的样本类内散度最小，而类间散度最大。

# LDA

- 假设有C类样本，第*i*类样本个数是 $N_i$ ， $\mu_i$ 是第*i*类样本的均值， $x_j^i$ 是第*i*类中第*j*个样本。
- 类内散度  $S_W = \sum_{i=1}^C \sum_j (x_j^i - \mu_i)(x_j^i - \mu_i)^T$
- 类间散度  $S_B = \sum_{i=1}^C N_i(\mu_i - \mu)(\mu_i - \mu)^T$
- 总体散度  $S_t = \sum_i (x_i - \mu)(x_i - \mu)^T$
- 容易证明  $S_t = S_W + S_B$

# LDA

- Fisher准则可以转化为最优化问题：寻找投影映射 $w$ 使得目标函数最大

$$J(w) = \arg \max_w \frac{|w^T S_B w|}{|w^T S_W w|}$$

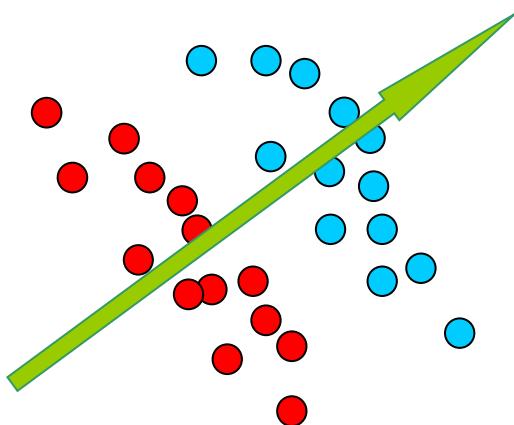
# 求解

- 可以转化成广义特征值问题：

$$S_B w = S_W w \Lambda$$

- 当 $S_W$ 非奇异时，上述问题等价于 $S_W^{-1}S_B$ 的特征值求解问题：

$$S_W^{-1}S_B w = w \Lambda$$



# 奇异问题

- 当样本个数小于特征维数时（小样本问题）， $S_W$ 是奇异的，无法求解。
- 解决方案：
  1. 用PCA对样本进行降维，使得 $S_W$ 非奇异。
  2. 直接在 $S_W$ 的零空间求解最优投影。
  3. 扰动法：在 $S_W$ 的对角上加小的扰动，使其非奇异。

# 线性方法的不足

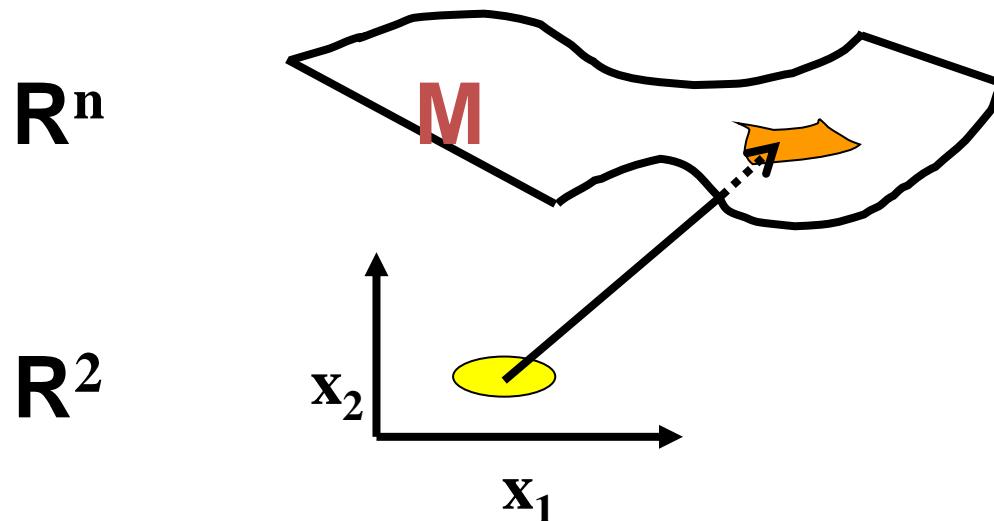
- 现实中数据的有用特性往往不是特征的线性组合。



# Manifold Learning

# 什么是流形？

- 定义1：如果一个 $N$ 维的拓扑空间 $M$ 内的任意一点都存在一个邻域 $U \in M$ ，使得该邻域是 $N$ 维欧氏空间的同胚，则这个拓扑空间 $M$ 被称为流形。



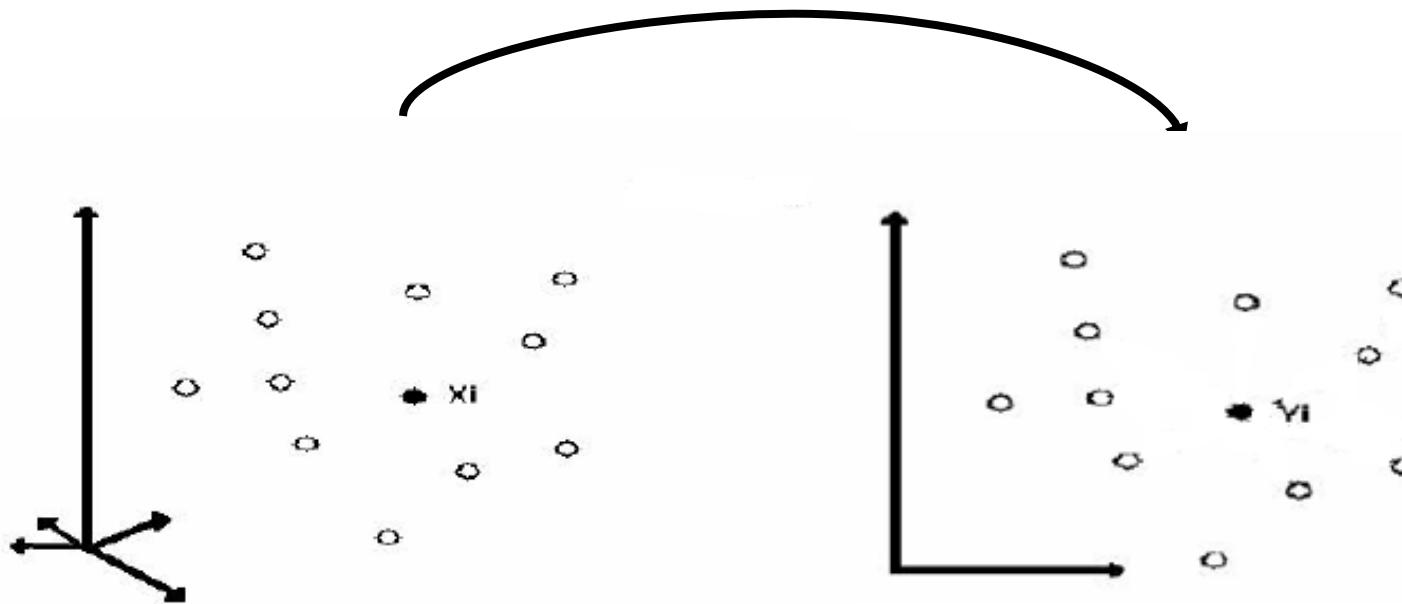
# 流形学习的数学基础

- 参考文献：
  - 陈省身, 陈维桓, 微分几何讲义. 北京大学出版社, 1983
  - 陈维桓, 微分流形初步(第二版). 高等教育出版社, 2001

# 什么是流形学习？

- 定义2：令 $Y$ 是包含在欧氏空间 $R^d$ 的 $d$ 维域， $f: Y \rightarrow R^N$ 为光滑嵌入，其中 $N > d$ 。数据点 $\{y_i\} \subset Y$ 是随机生成的，经 $f$ 映射形成观察空间的数据 $\{x_i = f(y_i)\} \subset R^N$ 。一般称 $Y$ 为隐空间， $\{y_i\}$ 为隐数据。流形学习的目标是要从观察数据 $\{x_i\}$ 中重构 $f$ 和 $\{y_i\}$ 。
- 流形是线性子空间的一种非线性推广.
- 流形是一个局部可坐标化的拓扑空间.

# 什么是流形学习？



# 流形学习的可行性

- 1 许多高维采样数据都是由少数几个隐含变量所决定的，如人脸采样由光线亮度，人离相机的距离，人的头部姿势，人的脸部肌肉等因素决定。
- 2 从认知心理学的角度，心理学家认为人的认知过程是基于认知流形和拓扑连续性的。



# 算法简介

- Sciences 2000年:
  - Tenenbaum等人: Isomap
  - Roweis和Saul: LLE
- NIPS, 2001年:
  - M.Belkin和P.Niyogi: Laplacian Eigenmaps
- NIPS & ICCV 2003:
  - Xiaofei He等人: LPP
- PAMI 2007:
  - Graph Embedding and Extensions: A General Framework for Dimension

# LLE

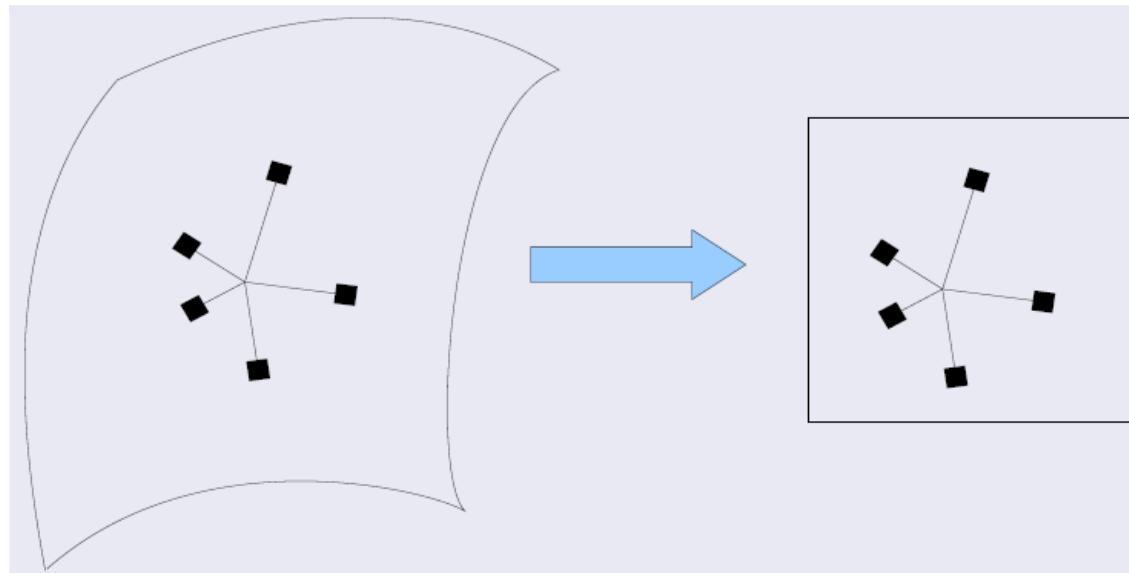
- S.T.Roweis and L.K.Saul

Nonlinear dimensionality reduction by locally linear embedding

Science 2000

# LLE

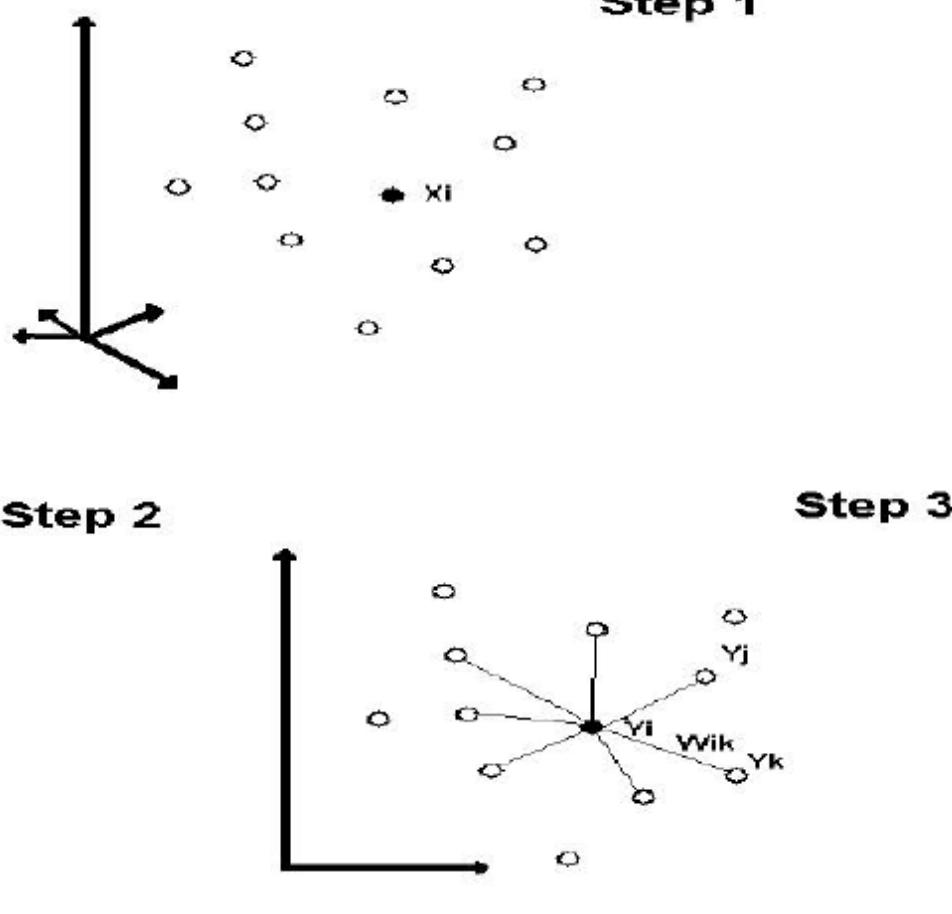
主要思想：LLE (Locally Linear Embedding) 算法强调在样本集结构不满足全局线性结构时，样本空间与内在低维子空间之间在局部意义下的结构可以用线性空间近似。



$$x_i \approx \sum W_{ij} x_j$$

# LLE

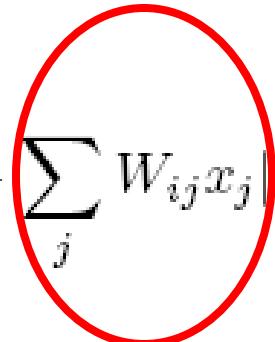
## ● 邻接图



# LLE

权值计算：

$$\xi(W) = \sum_i |x_i - \sum_j W_{ij}x_j|^2$$



学习目标：

在低维空间中保持每个邻域中的权值不变，即假设嵌入映射在局部是线性的条件下，最小化重构误差。

$$\xi(y) = \sum_i |y_i - \sum_j W_{ij}y_j|^2$$

# LLE

- 流程图：

**Step 1:** 构建邻域。对于原始空间任一给定样本点，用  $K$  近邻法得到它的一组邻域点。

**Step 2:** 计算权值。在第二步用权值  $W_{ij}$  描述原始空间任一点与其邻域的关系。权值  $W_{ij}$  是使得样本点  $x_i$  用它的相邻点  $x_j$  重构误差最小的解：

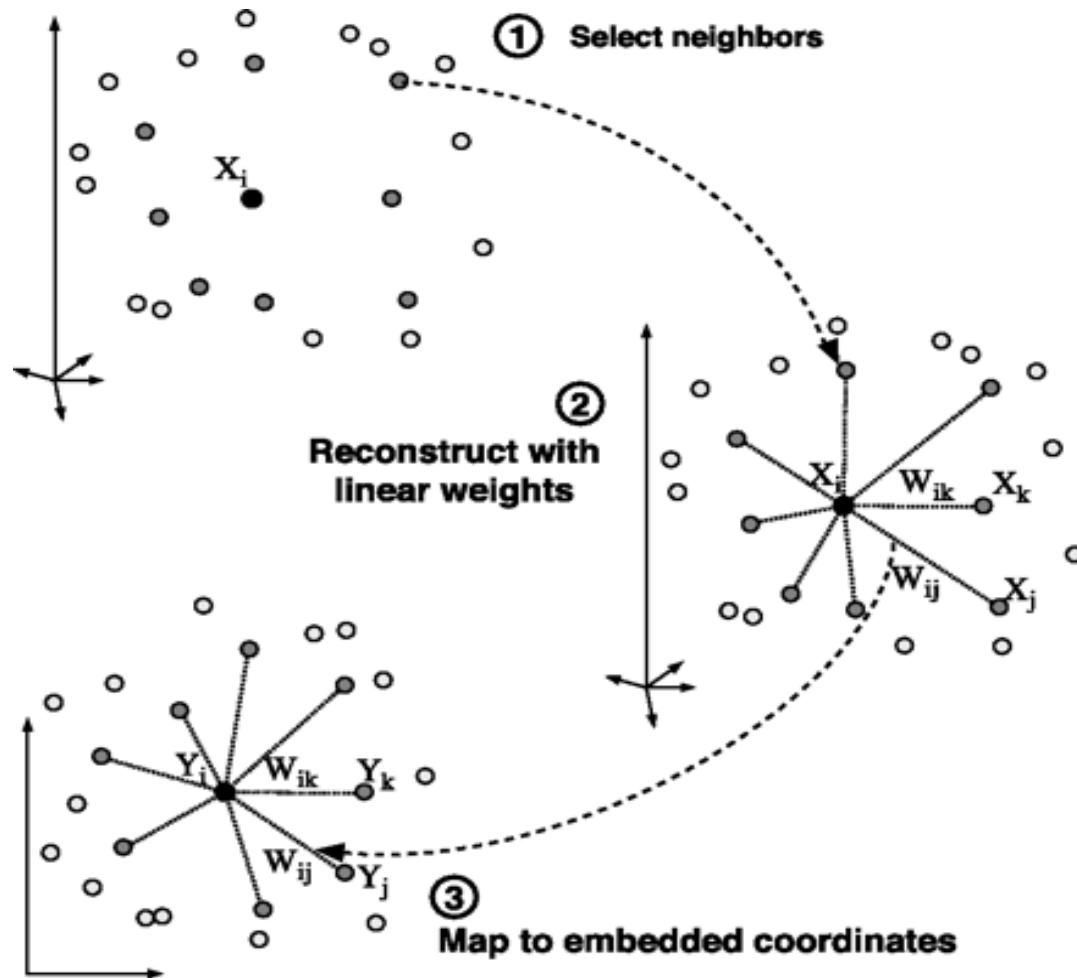
$$\xi(W) = \sum_i |x_i - \sum_j W_{ij} x_j|^2$$

**Step 3:** 嵌入。最后的嵌入通过最小化误差来保留尽可能多的原空间几何性质：

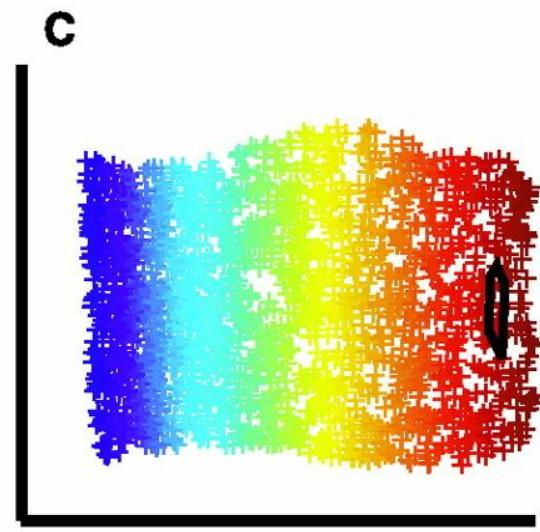
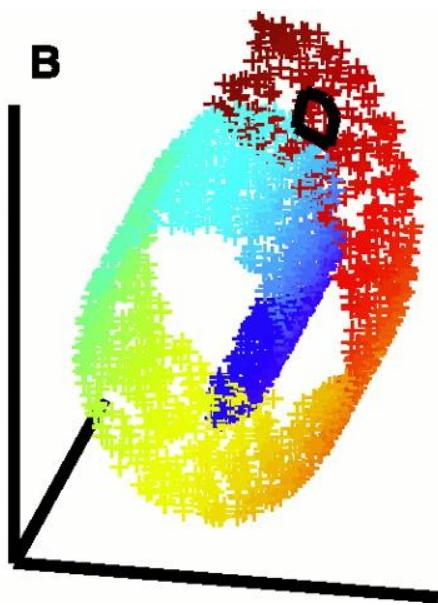
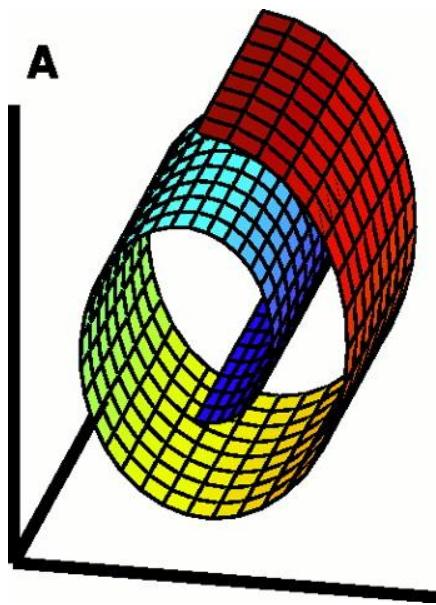
$$\xi(y) = \sum_i |y_i - \sum_j W_{ij} y_j|^2$$

这里  $W$  是第二步计算的权值， $y_i$  和  $y_j$  是样本点在嵌入空间的投影

# LLE算法示意图

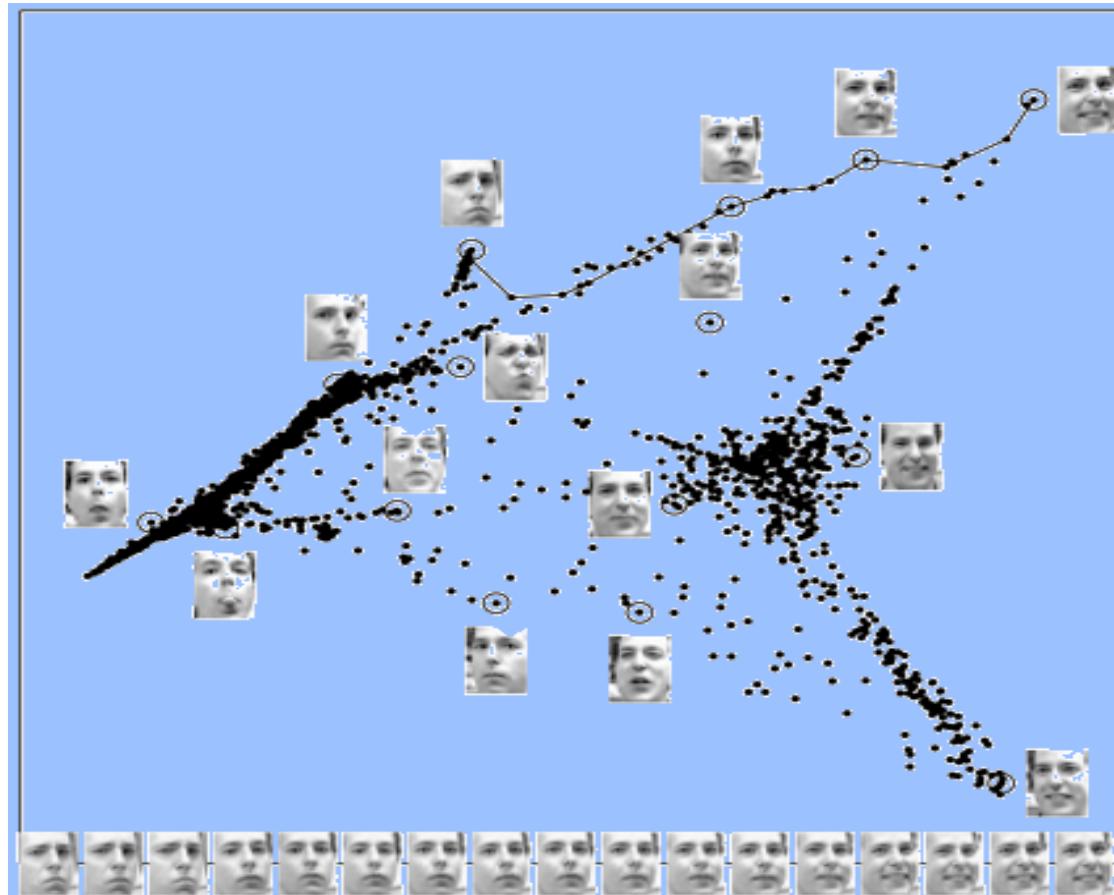


# 应用



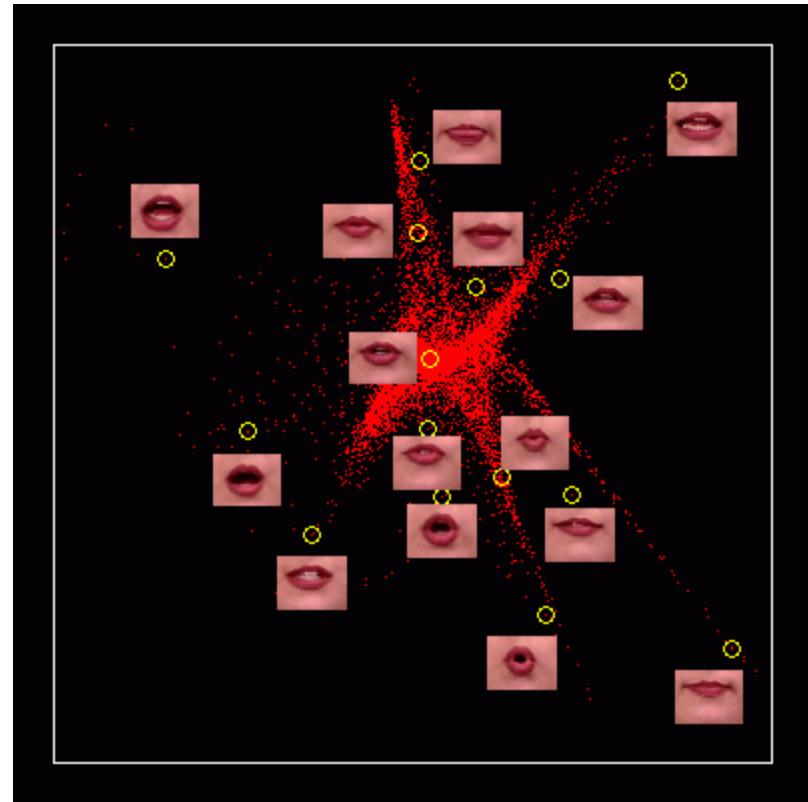
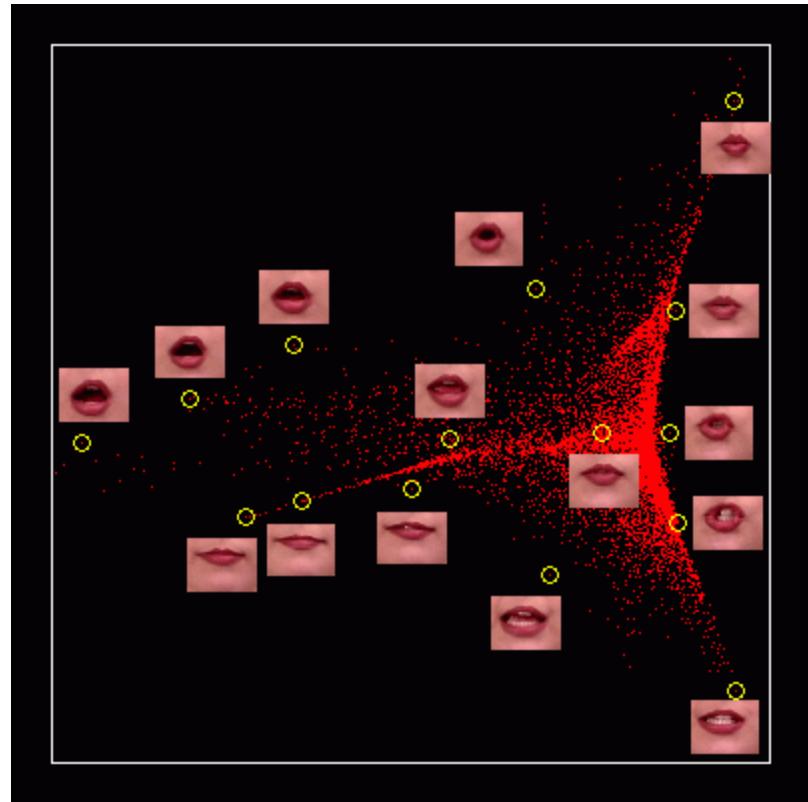
# 应用

- 人脸图像在2D流形空间的投影



# 应用

- 嘴唇图像在2D流形空间的投影



# LLE算法的优点

- LLE算法可以学习任意维数的低维流形.
- LLE算法中的待定参数很少， K和d.
- LLE算法中每个点的近邻权值在平移、旋转、伸缩变换下是保持不变的.
- LLE算法有解析的整体最优解，不需迭代.
- LLE算法归结为稀疏矩阵特征值计算，计算复杂度相对较小，容易执行.

# LLE算法的缺点

- LLE算法要求所学习的流形只能是不闭合的且在局部是线性的.
- LLE算法要求样本在流形上是稠密采样的.
- LLE算法中的参数K、d有过多的选择.
- LLE算法对样本中的噪音很敏感.

# Isomap (等距映射)

- J.B.Tenenbaum, V.D.Silva and K.C.Langford

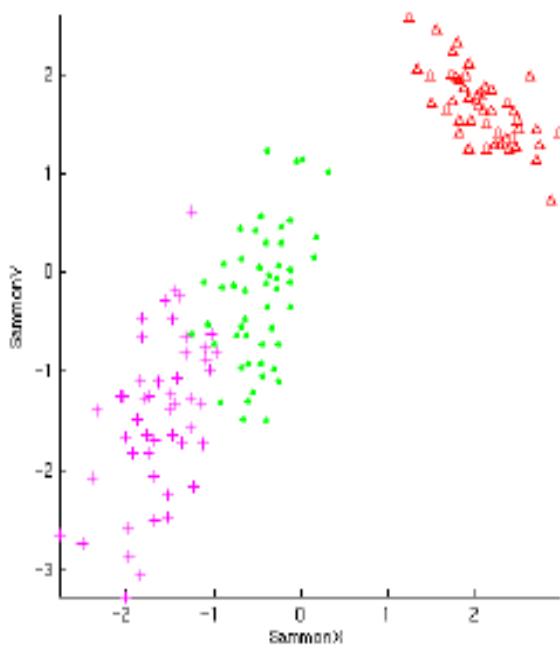
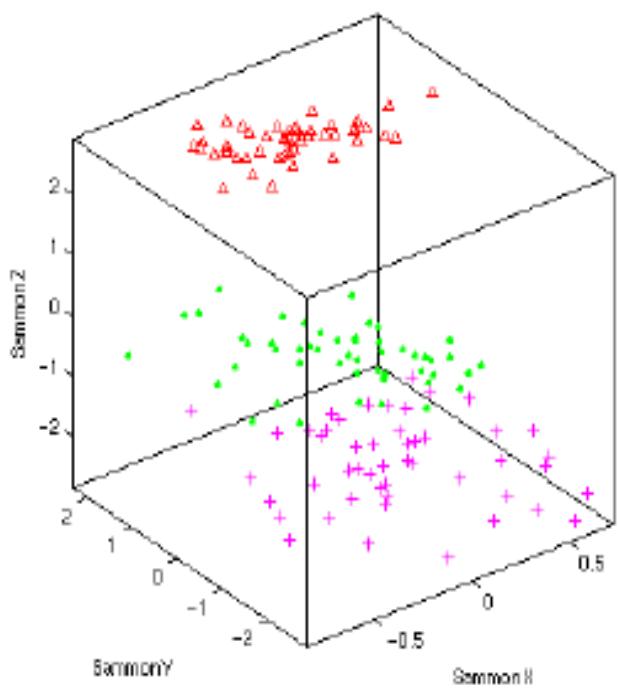
A global geometric framework for nonlinear dimensionality reduction

Science 2000

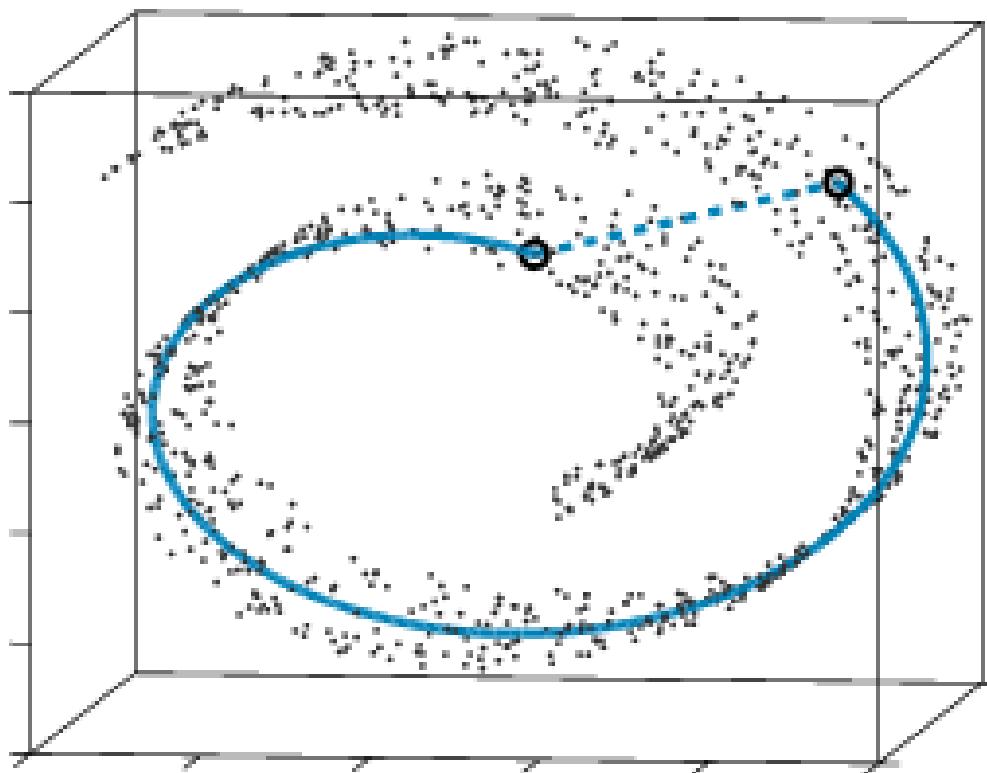
# 多维尺度变换 (MDS)

- MDS 是一种非监督的维数约简方法.
- MDS的基本思想：约简后低维空间中任意两点间的距离应该与它们在原始空间中的距离相同.
- MDS的求解：通过适当定义准则函数来体现在低维空间中对高维距离的重建误差，对准则函数用梯度下降法求解，对于某些特殊的距离可以推导出解析解法.

# MDS的示意图



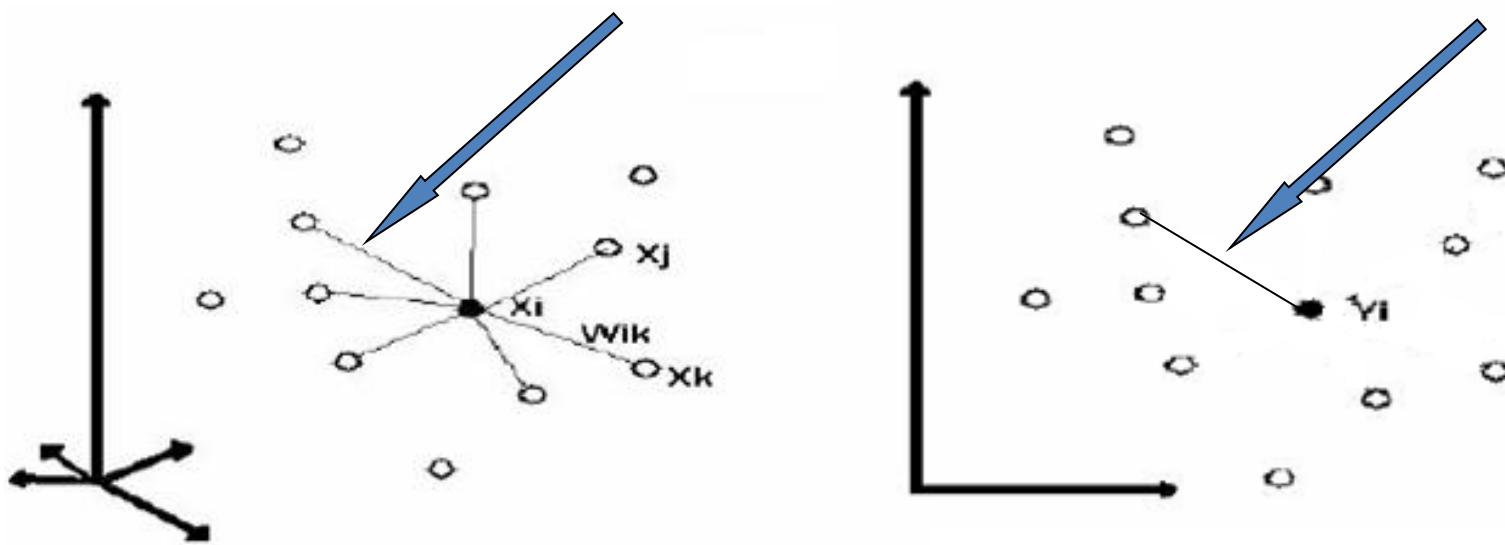
# MDS的失效



# Isomap

- 主要思想：  
建立在多维尺度变换(MDS)的基础上，力求保持数据点的内在几何性质，即保持两点间的测地距离，不是欧式距离。
- Isomap = MDS + 测地距离

# Isomap



# Isomap

流程图：

**Step 1:** 在样本集上构建近邻图  $G$ 。如果样本  $i$  和  $j$  之间距离小于某个阈值，或者他们为  $k$ -近邻，则连接  $i$  和  $j$

**Step 2:** 计算样本两两之间测地距离（用 Dijkstra 算法），建立测地距离矩阵  $D_G = d_G(x_i, x_j)$

**Step 3:** 利用 MDS 算法构造内在  $d$  维子空间，最小化下式

$$E = \| \tau(D_G) - \tau(D_Y) \|_{L^2}$$

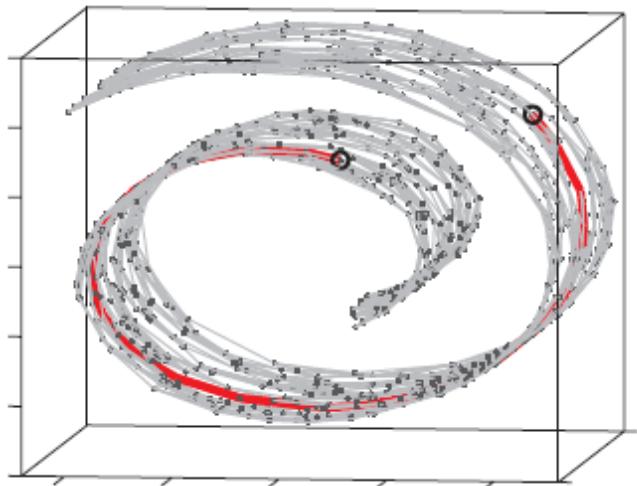
矩阵变换算子  $\tau(D) = -HSH/2$  将距离转换成 MDS 所需内积形式，其中  $S$  是平方距离矩阵， $\{S_{x_i x_j} = D_{x_i x_j}^2\}$ ， $H$  是集中矩阵

$$\{H_{x_i x_j} = \delta_{x_i x_j} - 1/N\}$$

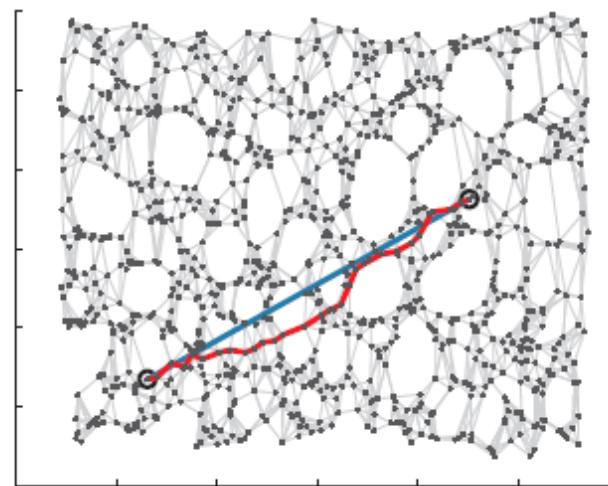
上式的最小值可以通过求矩阵  $\tau(D_G)$  的  $d$  个最大特征值对应的特征向量来实现

# 应用

- Swiss Roll在2D流形空间的投影



3维数据集

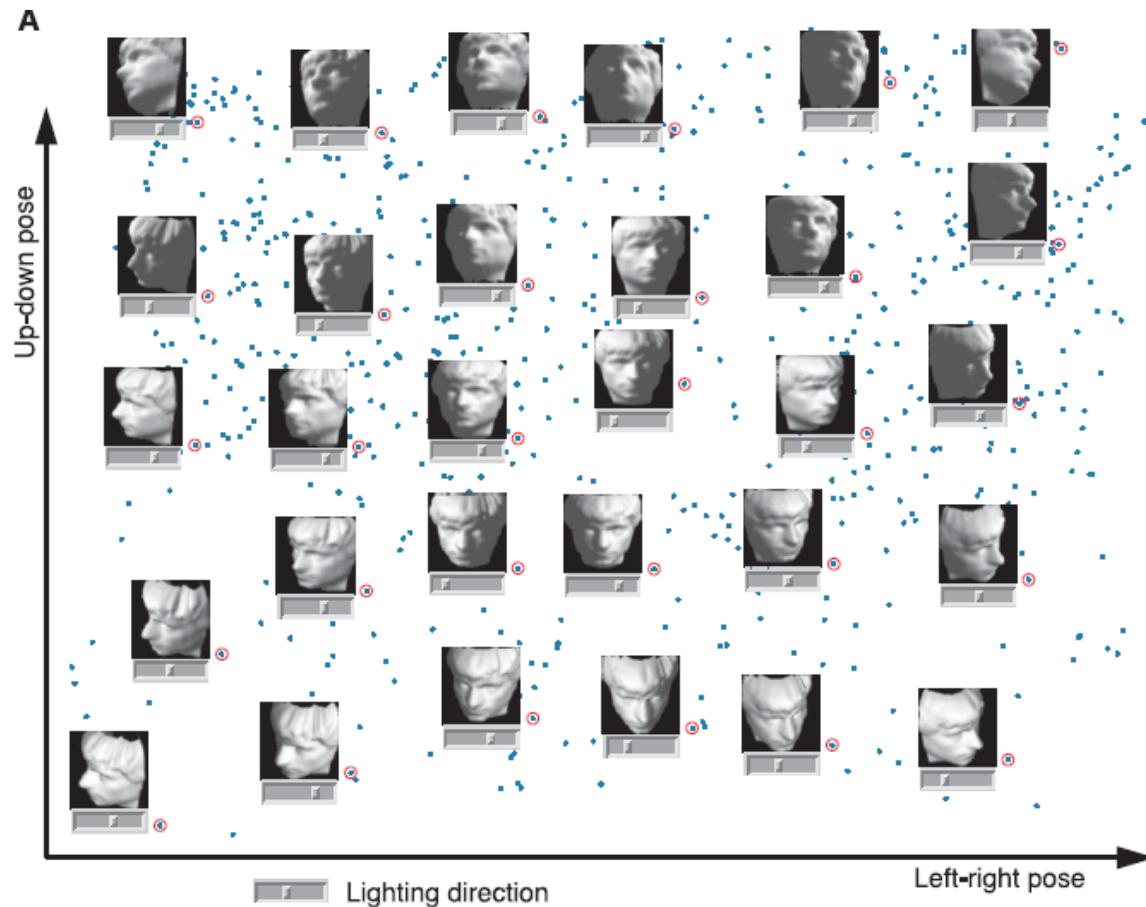


2维投影

# 应用

- 人脸图像在2D流形空间的投影

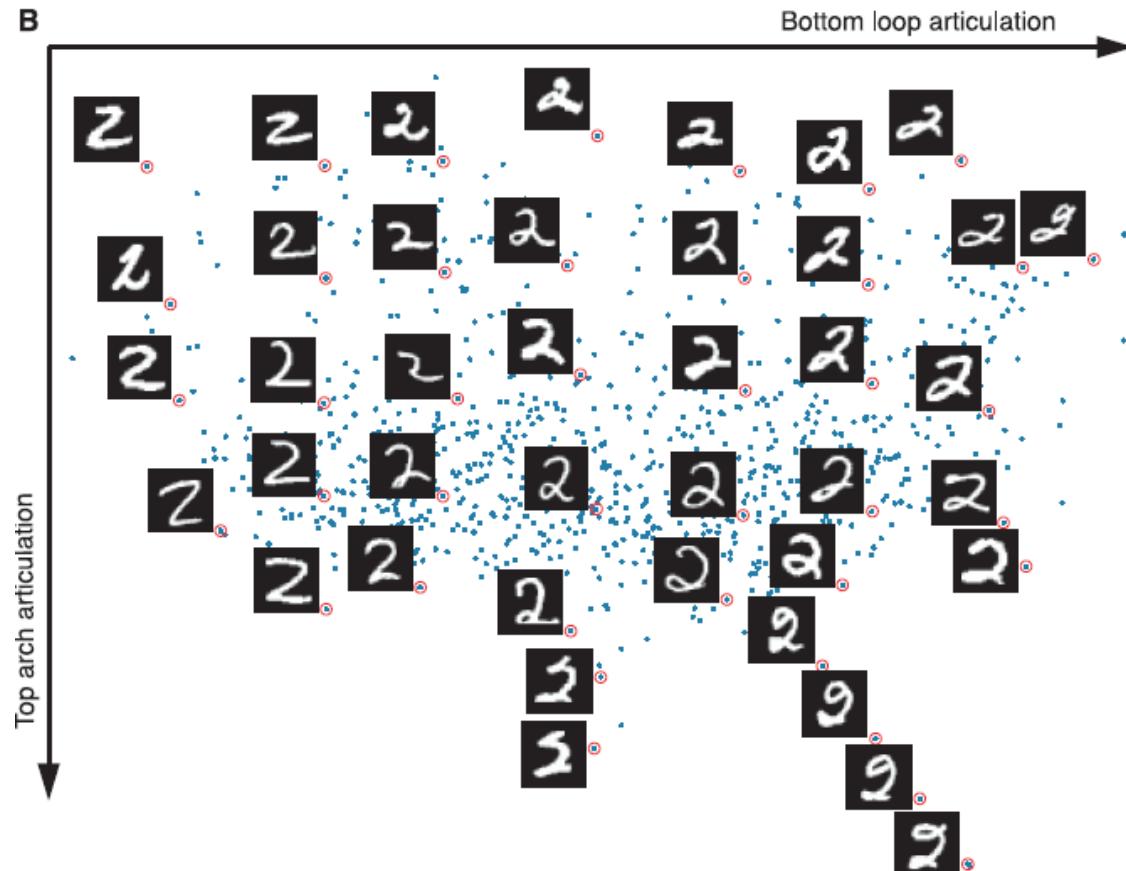
横坐标反映了光照变化，纵坐标反映姿态变化



# 应用

- 手写数字（2）在2D流形空间的投影

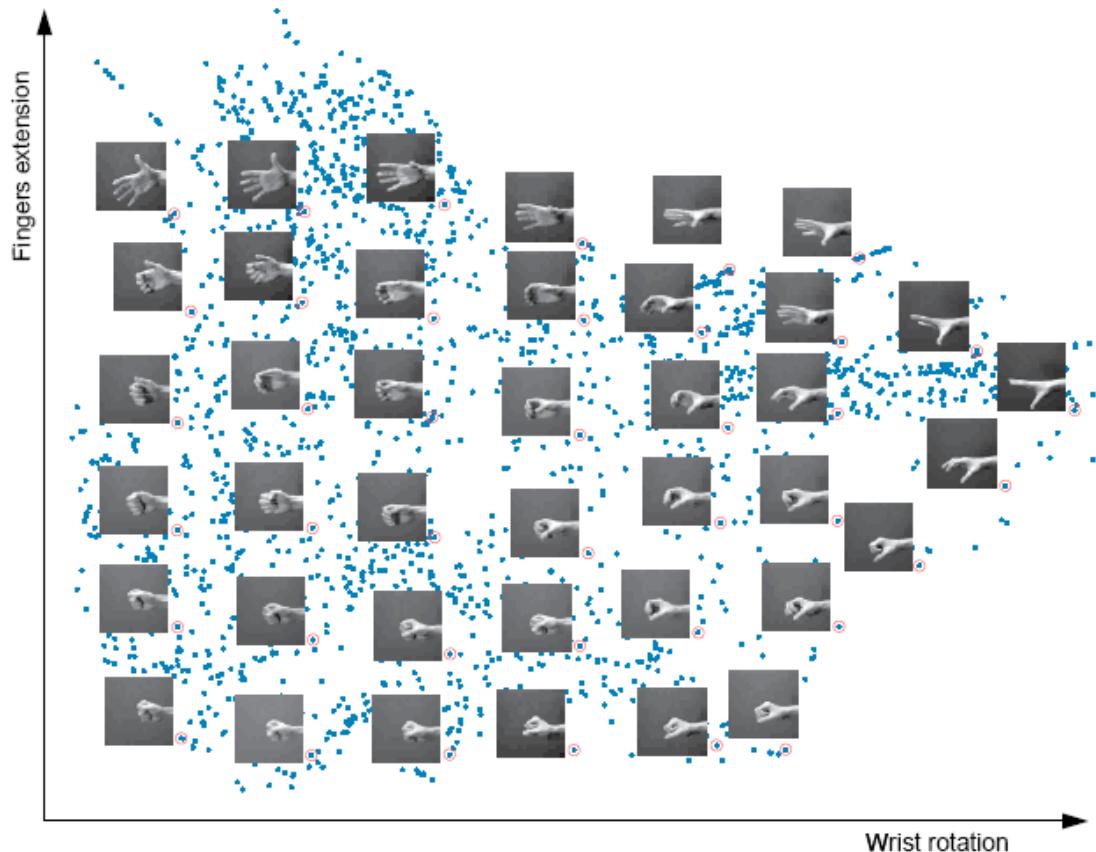
横坐标反映底部环型变化，纵坐标反映顶上穹型变化



# 应用

- 手势在2D流形空间的投影

横坐标反映手腕旋转变化，纵坐标反映手指的伸展变化



## Isomap算法的特点

- Isomap是非线性的，适用于学习内部平坦的低维流形、不适用于学习有较大内在曲率的流形。
- Isomap算法中有两个待定参数K、d。

# Laplacian Eigenmap

- M.Belkin and P.Niyogi

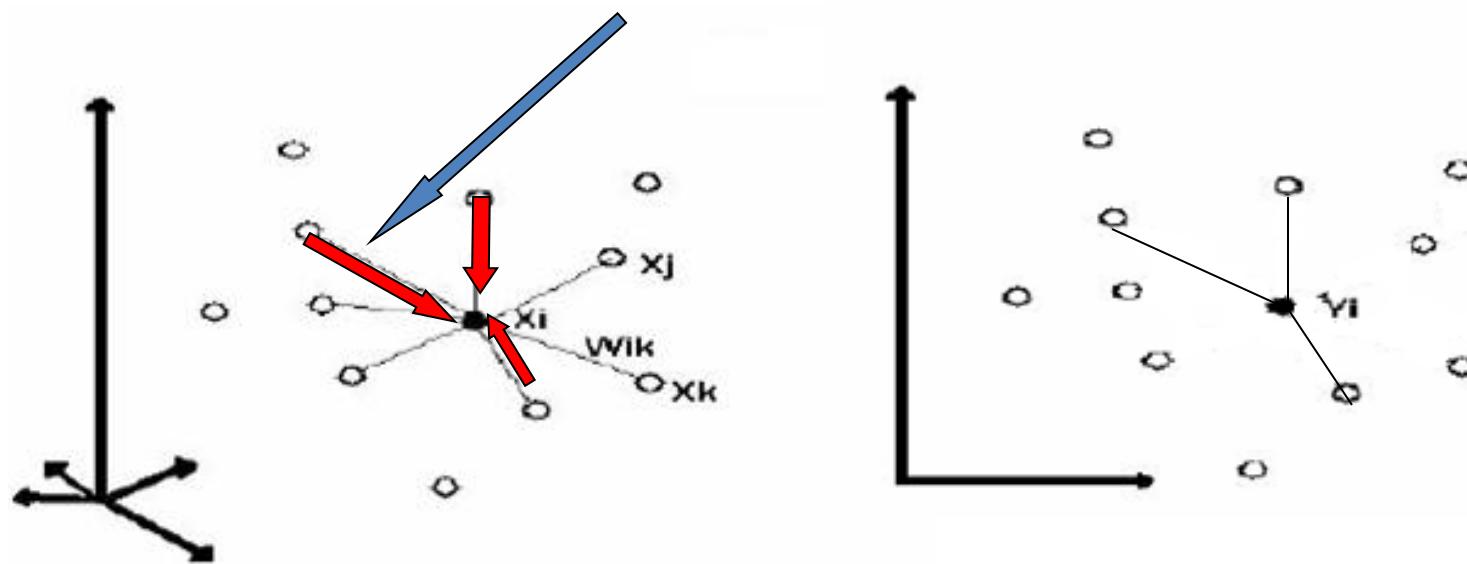
Laplacian eigenmaps and spectral techniques for  
embedding and clustering

NIPS 2001

# Laplacian Eigenmap

主要思想：

在高维空间中离得很近的点投影到低维空间中的像也应该离得很近.



# Laplacian Eigenmap

- 主要思想的数学表达：

令样本集:  $X = (x_1, x_2, \dots, x_n)$  投影后样本:  $y = (y_1, y_2, \dots, y_n)$

LE的目标是最小化目标函数:

$$\sum_{i,j=1}^n \|y_i - y_j\|^2 W_{ij}$$

# Laplacian Eigenmap

- 这里权值反映样本之间的关系，一般用热核表示：

$$W_{ij} = e^{-\frac{\|x_i - x_j\|^2}{t}}$$

也可以简单定义成1（节点i和j相邻）或0（不相邻）

- 为了使最小化问题解唯一，必须加上尺度归一的限制条件，目标函数变为：

$$\arg \min_{\mathbf{y}^T D \mathbf{y} = 1} \mathbf{y}^T L \mathbf{y}$$

这里  $L=D-W$  被称为 Laplacian 矩阵

$D_{ii} = \sum_j W_{ji}$  是对角矩阵

- 可以转化成广义特征值问题求解：

$$L\mathbf{y} = \lambda D\mathbf{y}$$

# Laplacian Eigenmap 算法的特点

- 算法是局部的非线性方法.
- 算法与谱图理论有很紧密的联系.
- 算法中有两个参数K、d.
- 算法通过求解稀疏矩阵的特征值问题解析地求出整体最优解.
- 算法使原空间中离得很近的点在低维空间也离得很近, 可以用于聚类.
- 没有给出显式的投影映射, 即对于新样本 (out-of-sample) 无法直接得到其在低维子流形上的投影

## LLE, Isomap, Laplacian Eigenmap有效的原因

- 1 它们都是非参数的方法，不需要对流形的很多的参数假设.
- 2 它们是非线性的方法，都基于流形的内在几何结构，更能体现现实中数据的本质.
- 3 它们的求解简单，都转化为求解特征值问题，而不需要用迭代算法.

# 目前流形学习研究的一般模式

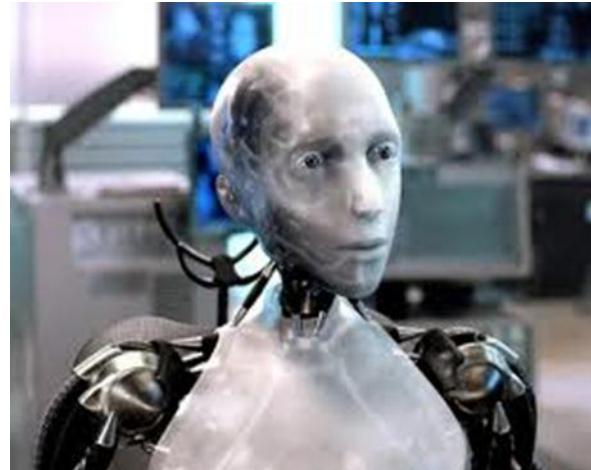
- 1 对嵌入映射或者低维流形作出某种特定的假设，或者以保持高维数据的某种性质不变为目标。
- 2 将问题转化为求解优化问题。
- 3 提供有效的算法。

# 流形学习中存在的问题

- 如何确定低维目标空间的维数？
- 当采样数据很稀疏时，怎样进行有效的学习？
- 将统计学习理论引入流形学习对其泛化性能进行研究。

# 深度学习与人脑工程

# 深度学习



- 微软美国研究院院长Peter Lee：“深度学习激起了人工智能领域新的挑战。”
- 美国《麻省理工评论》评选出2013年度10大突破性技术,深度学习(Deep Learning)居首。
  - 借助深度学习,人们在语音识别、图像识别领域取得了突飞猛进的进步。2012年6月, Google公司的深度学习系统在识别物体的精确度上比上一代系统提高了一倍,并且大幅度削减了Android系统语音识别系统的错误率。2012年12月,微软亚洲研究院展示了中英即时口译系统,错误率仅为7%。

# 深度学习的发展历史

人工神经网络

浅层学习

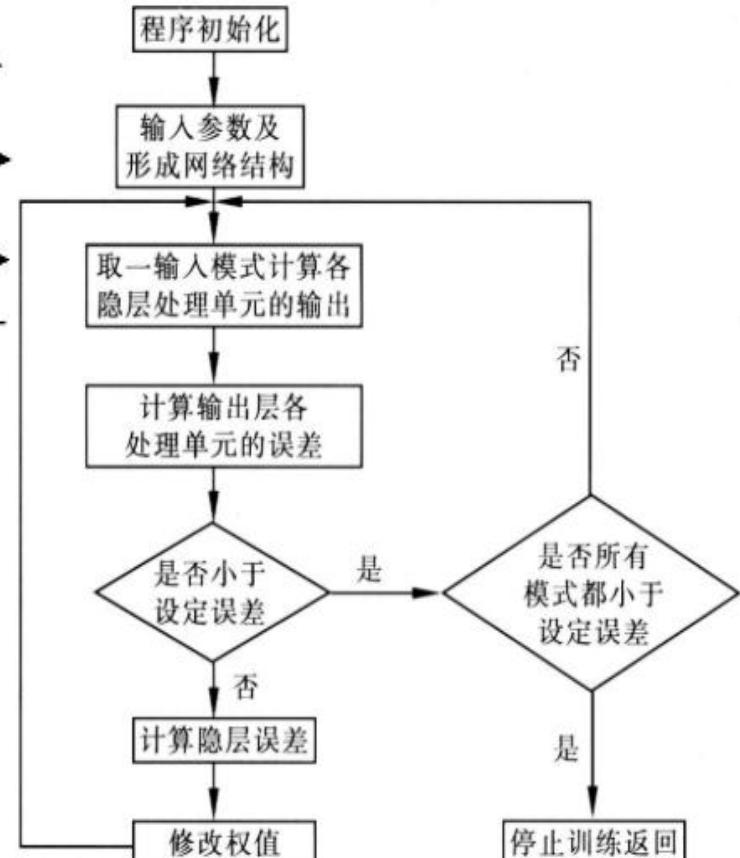
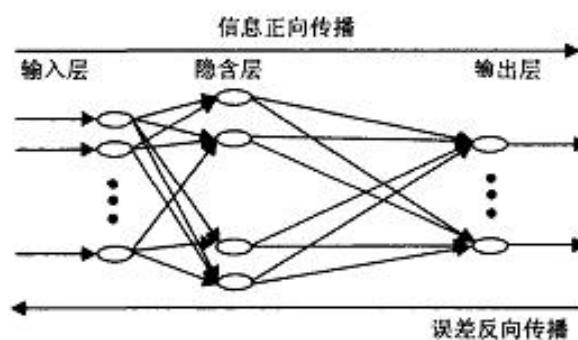
深度学习

80年代末期，BP算法提出。

1968年，《感知机》中指出线性感知机的功能是有限的，它不能解决如异或这样的基本问题；

50年代末，Rosenblatt提出了感知机模型；

1943年，McCulloch 和 Pitts提出神经元的数学模型；



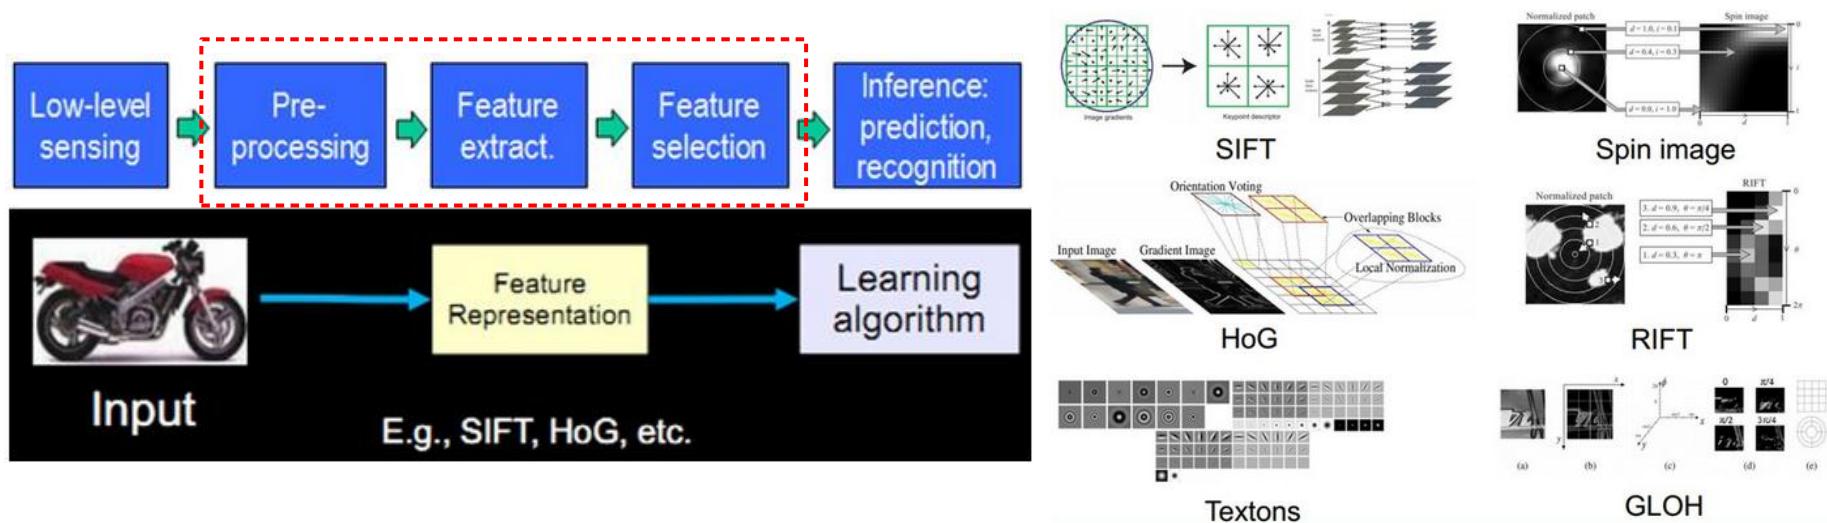
# 深度学习的发展历史

人工神经网络

浅层学习

深度学习

90年代，SVM、Boosting、最大熵  
方法等方法相继被提出

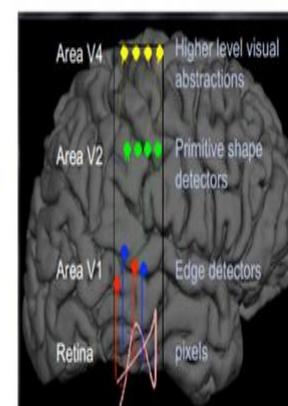
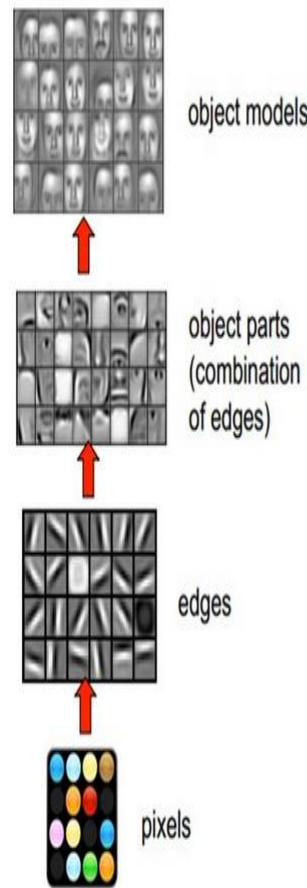
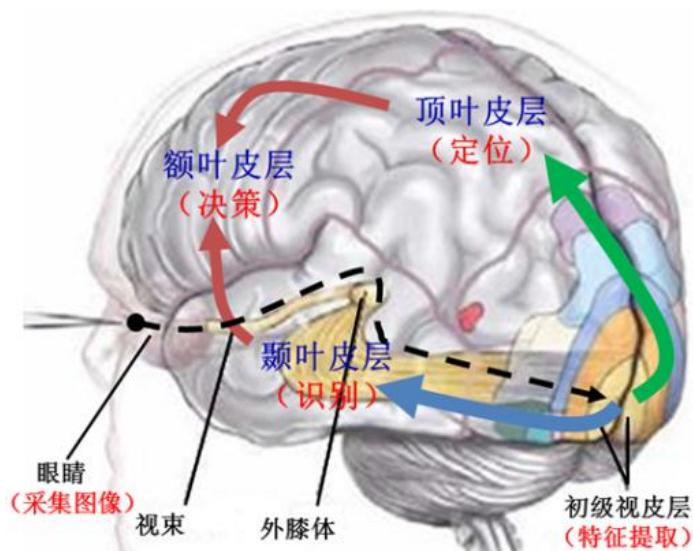


# 深度学习的发展历史

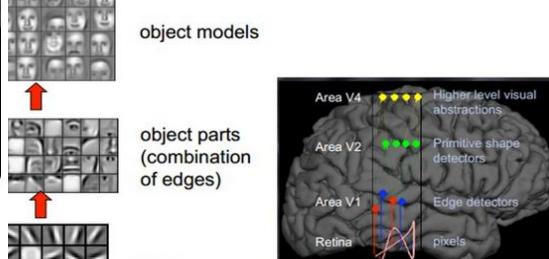
人工神经网络

浅层学习

深度学习

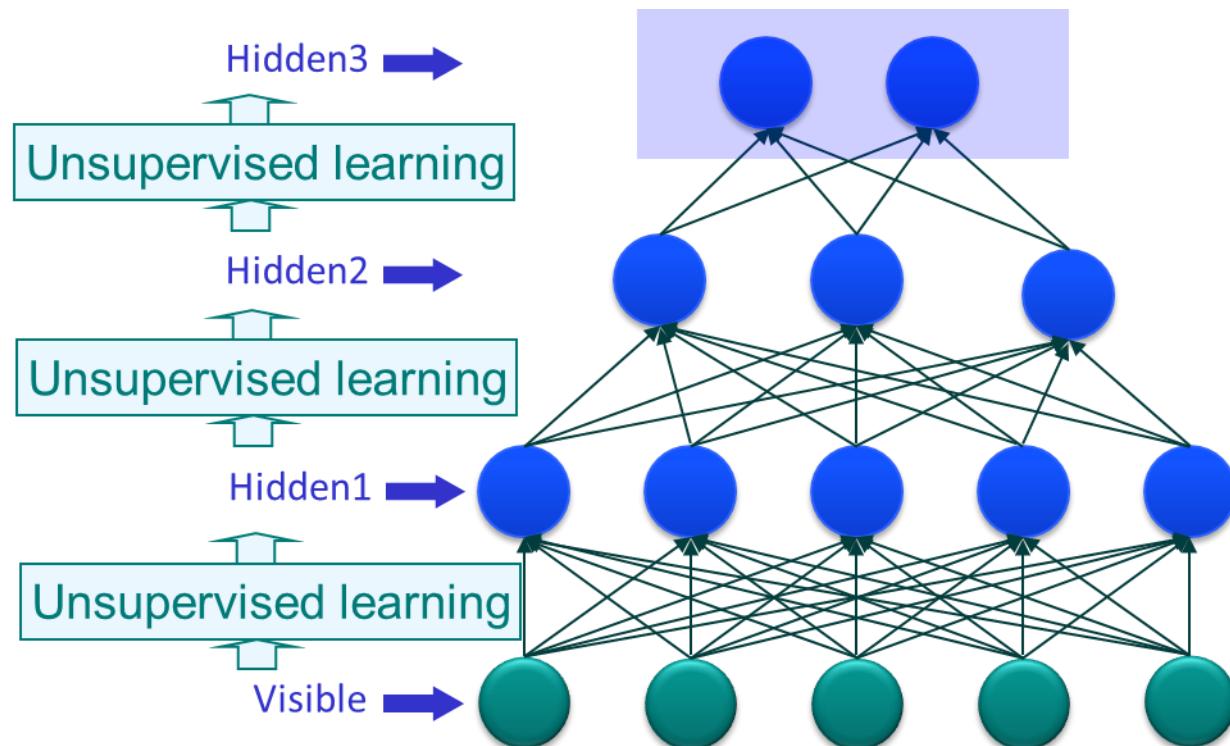


2006年，Hinton等人提出了深度学习的方法



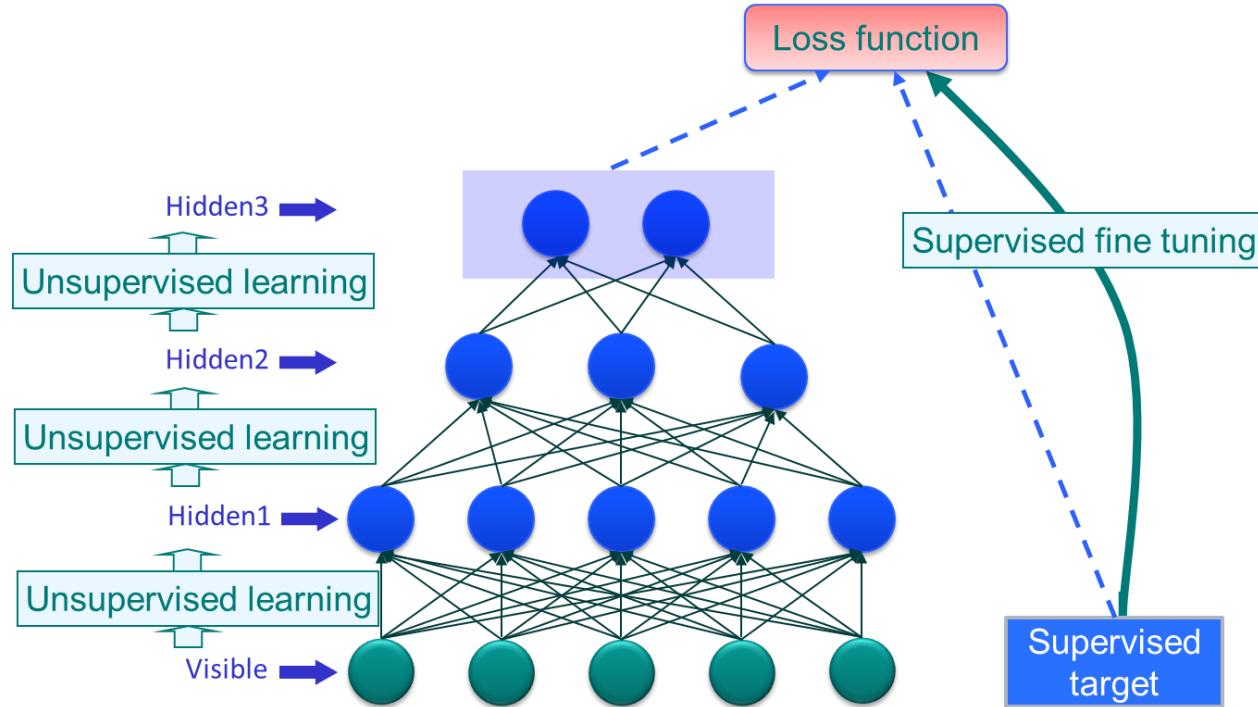
# 深度学习的基本设计思想

- 堆叠多层网络，即将低一层的输出作为高一层的输入。



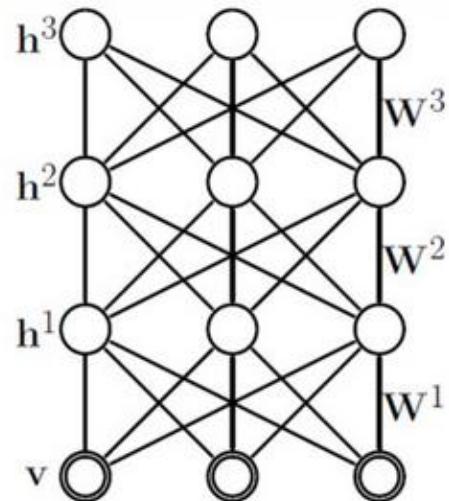
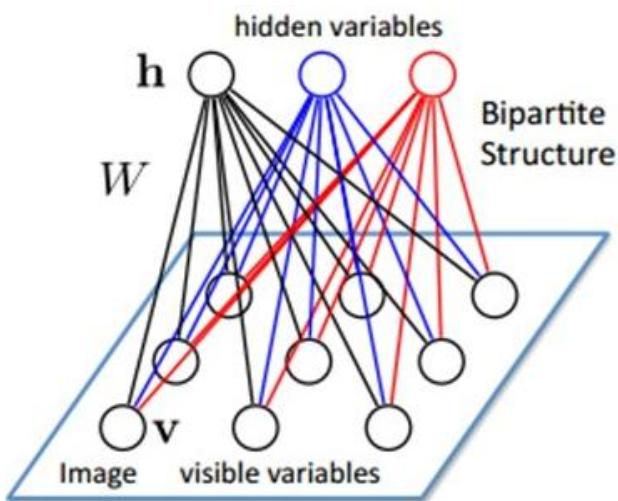
# 深度学习的训练过程

- 逐层的无监督训练：由最底层开始；
- fine-tune**：基于第1步得到的各层参数，整体优化整个网络的参数。

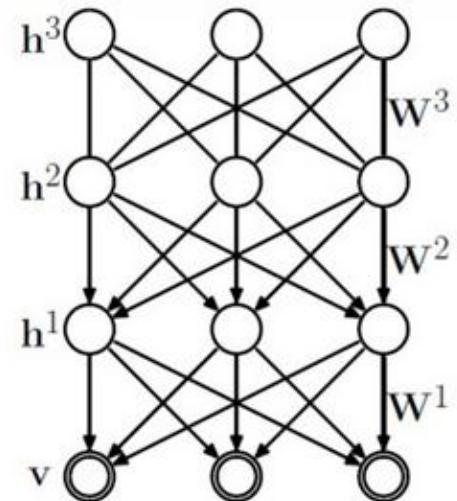


# 深度学习的常用模型

- 受限的玻尔兹曼机(RBM, Restricted Boltzmann Machine)



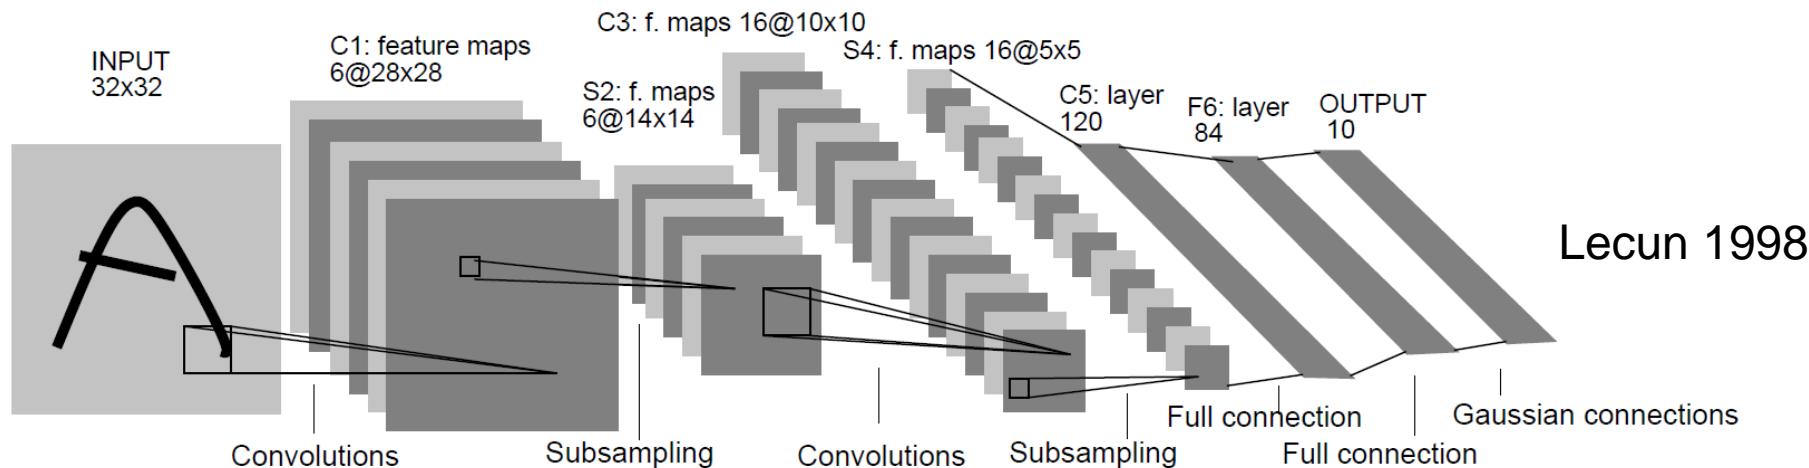
Deep Boltzmann Machine



Deep Belief Network

# 深度学习的常用模型

- 卷积神经网络(Convolutional Neural Networks)
  - 第一个真正成功训练的多层网络结构



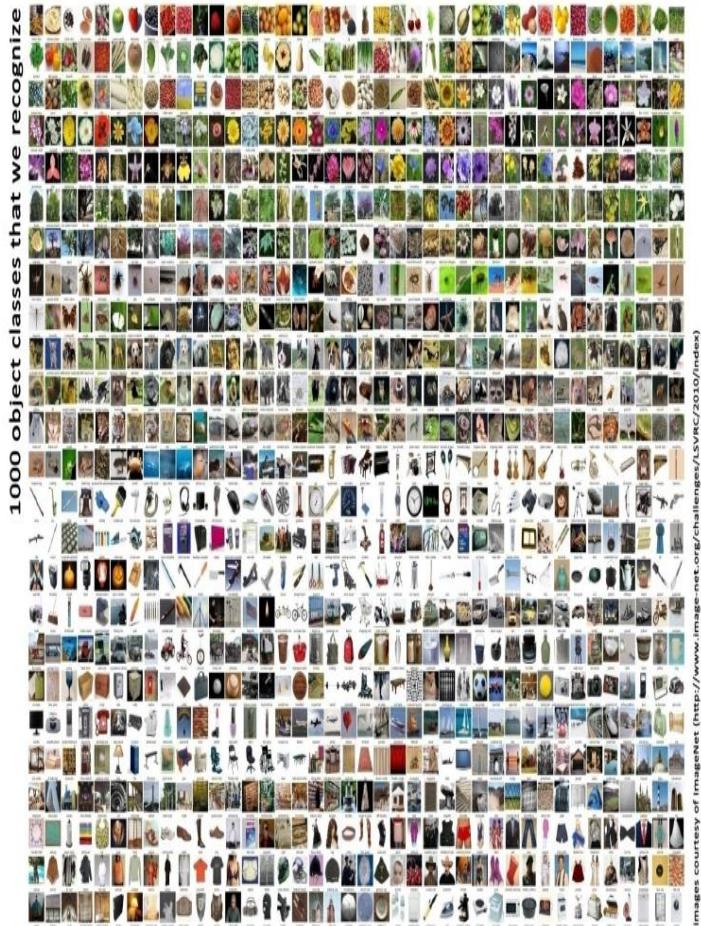
3 6 8 / 7 9 6 6 9 1  
6 7 5 7 8 6 3 4 8 5  
2 1 7 9 7 1 2 8 4 5  
4 8 1 9 0 1 8 8 9 4  
7 6 1 8 6 4 1 5 6 0  
7 5 9 2 6 5 8 1 9 7  
1 2 2 2 2 3 4 4 8 0  
0 2 3 8 0 7 3 8 5 7  
0 1 4 6 4 6 0 2 4 3  
7 1 2 8 1 6 9 8 6 1



Sermanet,Lecun 2011

# 深度学习的应用

- 图像分类



**72%, 2010**

**74%, 2011**

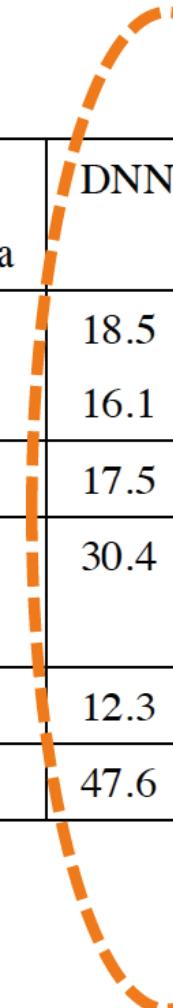
**85%, 2012**

**89%, 2013**

# 深度学习的应用

- 语音识别

task	hours of training data	DNN-HMM	GMM-HMM with same data
Switchboard (test set 1)	309	18.5	27.4
Switchboard (test set 2)	309	16.1	23.6
English Broadcast News	50	17.5	18.8
Bing Voice Search (Sentence error rates)	24	30.4	36.2
Google Voice Input	5,870	12.3	
Youtube	1,400	47.6	52.3



Slide Courtesy: Geoff Hinton

# 深度学习在工业界的应用

Google

Baidu 百度



YAHOO!

facebook.

 Microsoft

The Microsoft logo features a square divided into four colored quadrants: top-left is orange, top-right is green, bottom-left is blue, and bottom-right is yellow.

amazon

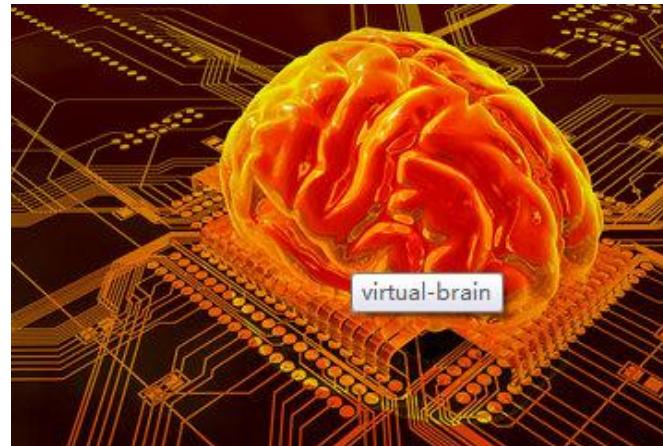
# 深度学习在工业界的应用

## • 谷歌虚拟脑

—16000多个处理器、10亿个内部节点，1000万帧从Youtube上随机抓取的无标签视频剪辑图片，利用了10天时间，终于“领悟”了什么是猫，并从接下来输入的2万张图片中准确找出了有猫的照片；

—Google语音识别软件就单字错误检出率而言正确率有了20%-25%的提升；

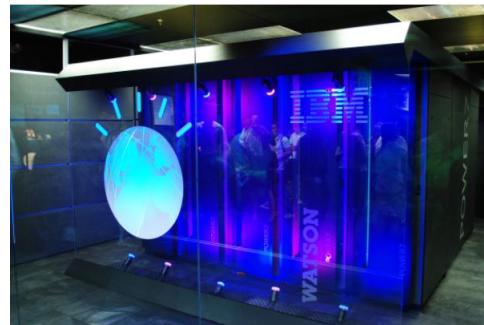
—门牌识别，识别精确率已达到90%以上；



# 深度学习在工业界的应用

## • IBM

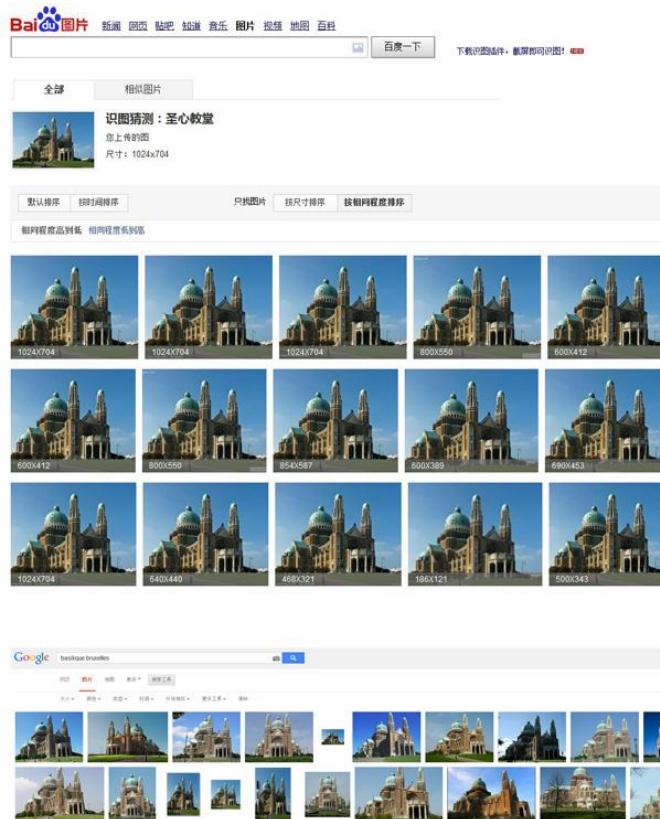
- IBM 宣布将斥资 10 亿美元为 Watson 组建新的业务部门利用自然语言能力和分析功能像人思考问题一样去处理信息，它可以迅速分析和处理大量的数据。
- Watson 已能观看并理解视频内容；用多种途径回答用户的问题，并能通过画图去回答问题；
- 已与几家著名的癌症治疗中心进行合作，已经可以为癌症患者推荐个性化治疗方案，并以优先顺序提供选项以供其选择；
- Watson凭借“高智商”已经在华尔街花旗集团找到了一份工作，负责证券投资组合管理。



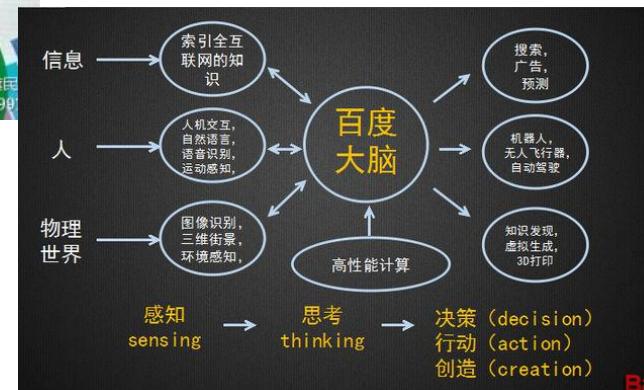
# 深度学习在工业界的应用

## • 百度

- 硅谷人工智能实验室
- 北京深度学习实验室
- 北京大数据中心

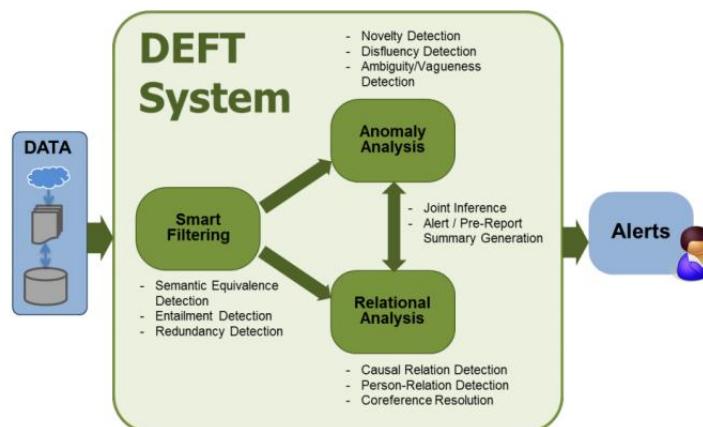


深度学习对百度的影响深远，如语音，错误率相对降低20-30%；OCR，错误率相对降低30%；人脸识别，LFW测试世界领先，世界上首个全网人脸搜索引擎；全网相似图像搜索，效果显著超越国际搜索引擎同类产品；全流量上线广告CTR预估，提升CTR3.7%；基于深度学习的色情图像识别准确率超过传统方法100%，用于贴吧图搜黄反作弊。



# 深度学习在工业界的应用

- DARPA美国国防部高级研究计划局
  - 2012年启动
  - 理解人类语言的深度学习技术，可以自动向情报分析人员汇报有用信息。
  - 自动化的深度自然语言处理（NLP）技术是高效处理文本信息并理解文本之间隐含关联的有效解决途径。DARPA启动DEFT项目的目的的是为了驾驭NLP的威力。类似NLP的复杂人工智能技术，可以大幅提高国防分析师调查和处理文档的效率，从而发现一些隐秘的，可以指导行动的有用信息。



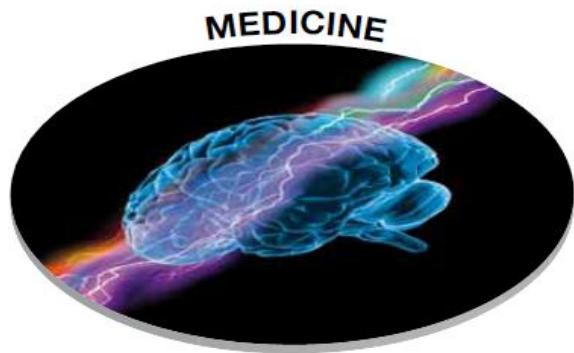
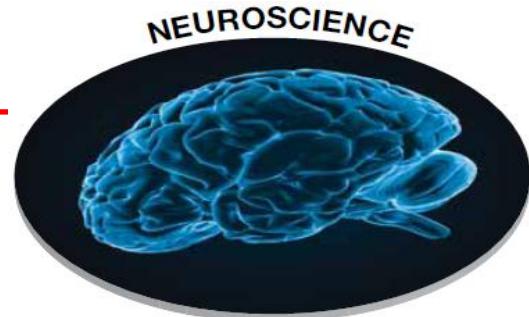
# 深度学习资料

- 课程与资料：
  - [http://deeplearning.stanford.edu/wiki/index.php/UFLDL\\_Tutorial](http://deeplearning.stanford.edu/wiki/index.php/UFLDL_Tutorial) (Andrew Ng)
  - Neural Networks for Machine Learning(Hinton)
  - Deep learning methods and applications (Deng Li)
  - .....
- <http://blog.csdn.net/zouxy09/article/details/8781396> (深度学习笔记)
- Deeplearning.net,.....
- ICML、NIPS、ICLR,.....

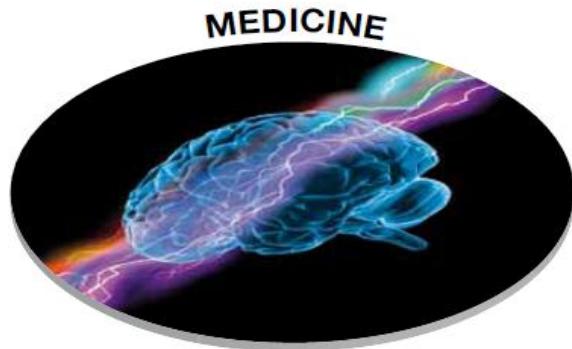
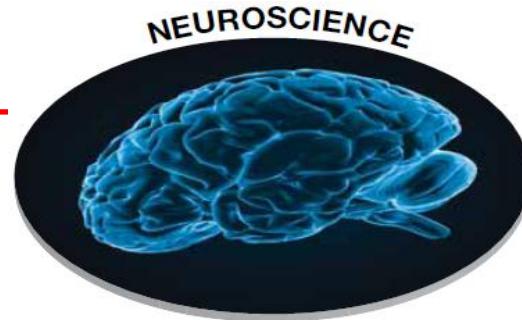
# 欧盟人脑计划 (HBP)

- 项目简介：2013年1月28日，欧盟委员会正式宣布选择人脑工程作为未来新兴技术旗舰计划的两个项目之一来支持的。人脑项目将历时10年(2013-2023)，预计费用将达到11.9亿欧元。将有来自23个国家（其中16个是欧盟国家）的大学、研究机构和工业界的87个组织参与该工程。
- 科学目标：人脑项目（HBP）旨在归纳对人类脑部现已掌握的知识，希望打造一个综合的基于信息通信技术的研究平台，通过超级计算机来逐步构建出最详细的人脑模型，用计算机模拟的方法研究人类大脑是如何工作的。该模型将使人类最终了解我们的大脑和脑部疾病，并为未来的计算机和机器人技术提供一个全新的前景。

# 欧盟人脑计划 (HBP)



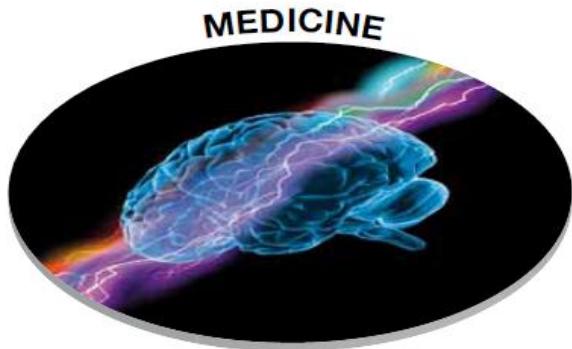
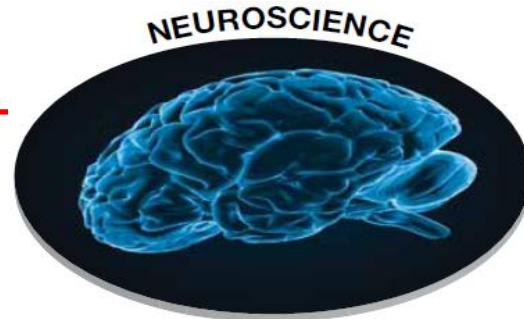
# 欧盟人脑计划（HBP）



通过神经信息学和脑模拟，可获取相关实验数据，并进行集成，从而识别并填补对大脑认知的空白，对未来的工作具有极大的向导、启发价值。

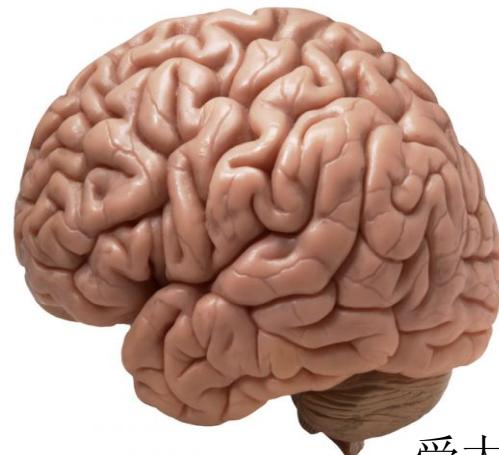
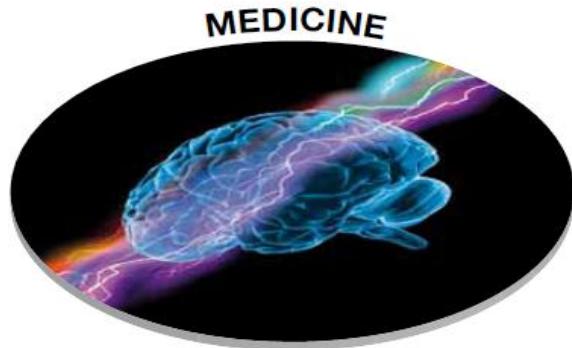
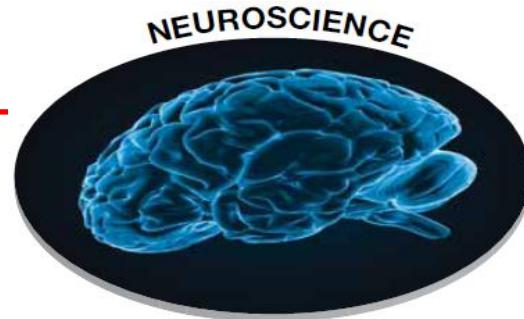


# 欧盟人脑计划（HBP）



通过医学信息学的研究可识别出大脑疾病的特征，在疾病对大脑导致不可逆的损坏之前的早期阶段治愈疾病，并根据病人个体特点和需求开展个性化治疗。通过疾病和药物的模拟，可加速新药物的研发。

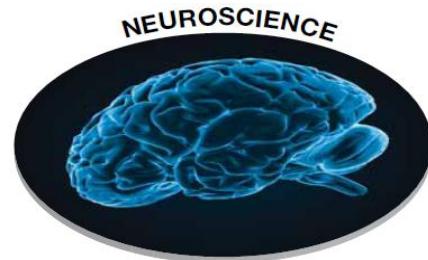
# 欧盟人脑计划（HBP）



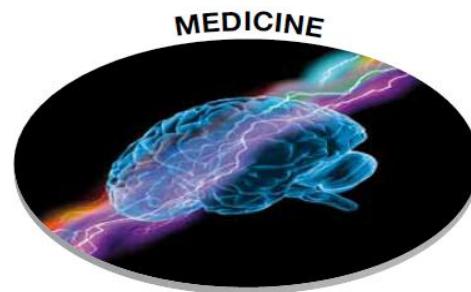
受大脑信息处理机制启发而设计的新设备与系统将，以克服现有系统能耗、可靠性、可编程能力等基础性缺陷，为实现类脑智能系统扫清障碍。

# 欧盟人脑项目 HBP：应用

- 揭示认知的统一理论；



- 理解、诊断、治疗神经和精神有关的疾病；



- 发展未来计算技术；



# 欧盟人脑计划（HBP）：组织机构

- 正式文件中涉及的核心单位14家。
  - 官方网站显示目前参与单位共计125个。
  - 约每年投入715人在项目中全时工作。

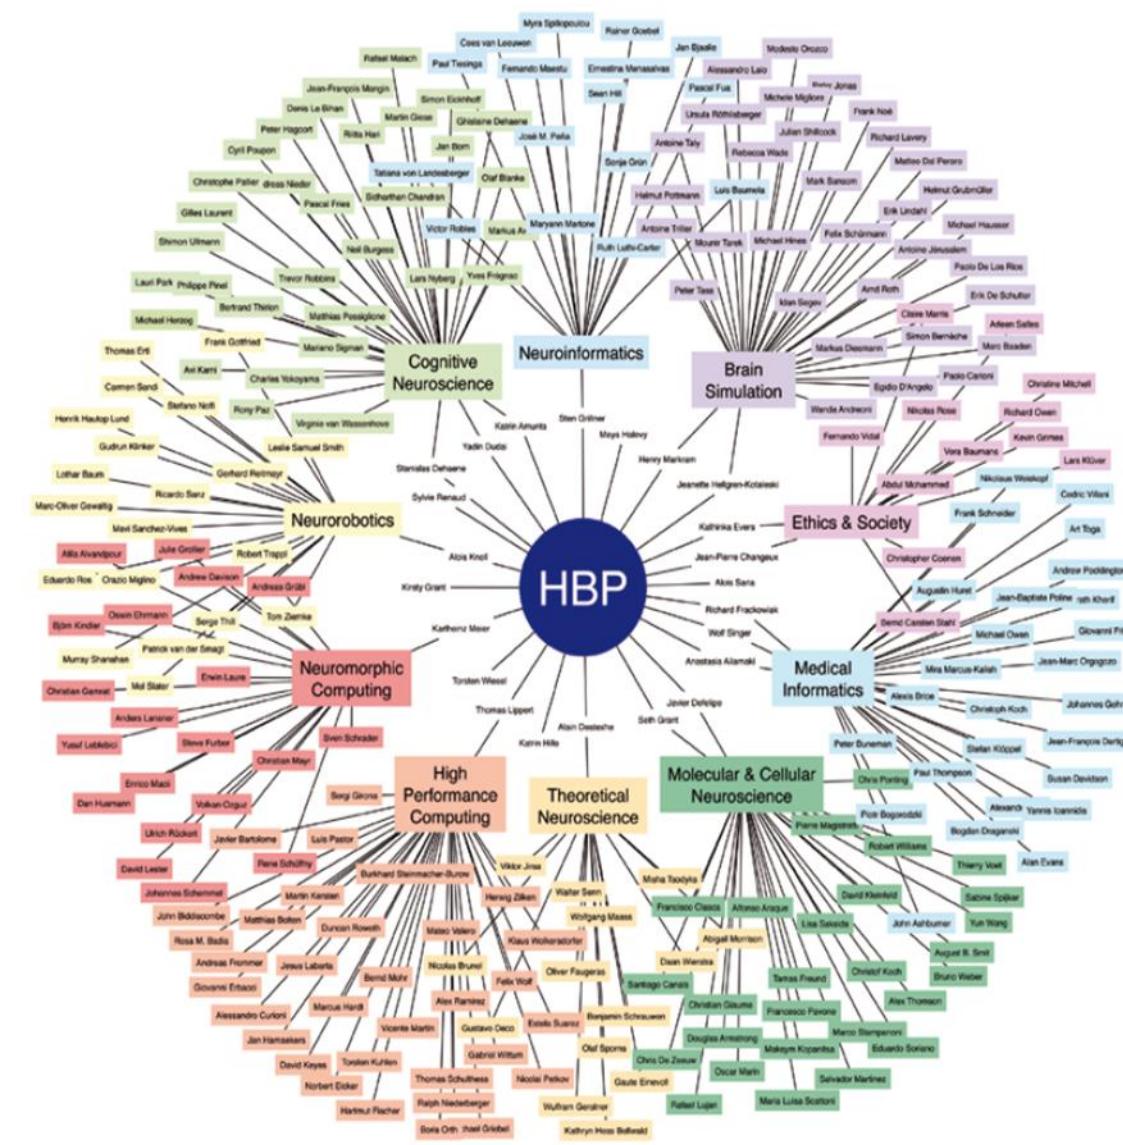


Figure 38: Scientists identified to participate in the HBP. The scientists listed have agreed to participate in the HBP, if it is approved as a FET Flagship

Division	Person-Years
Molecular & Cellular Neuroscience	646
Cognitive Neuroscience	996
Theoretical Neuroscience	559
Medical Informatics	538
Neuroinformatics	584
Brain Simulation	803
High Performance Computing	1'032
Neuromorphic Computing	341
Neurorobotics	887
Society & Ethics	196
Management	566
<b>TOTAL</b>	<b>7'148</b>

Table 4: HBP: personnel effort per division for the full duration of the project (person years)

# The HBP Report, April 2012

# 美国BRAIN计划

**项目简介：**2013年4月2日，美国白宫正式公布脑科学研究计划(BRAIN project)，以深入到微观水平探索人类大脑工作机制，绘制脑活动全图，针对无法治愈的大脑疾病开发新疗法。美国国立卫生研究院（NIH）、卡夫利基金会、艾伦脑科学研究所和霍华德•休斯医学学会（HHMI）等将作为核心单位参加。

**主要研究领域：**NIH在2014财年重点资助的9个大脑研究领域如下：

- 1)统计大脑细胞类型；
- 2)建立大脑结构图；
- 3)开发大规模神经网络记录技术；
- 4)开发操作神经回路的工具；
- 5)了解神经细胞与个体行为之间的联系；
- 6)把神经科学实验与理论、模型、统计学等整合；
- 7)描述人类大脑成像技术的机制；
- 8)为科学研究建立收集人类数据的机制；
- 9)知识传播与培训.

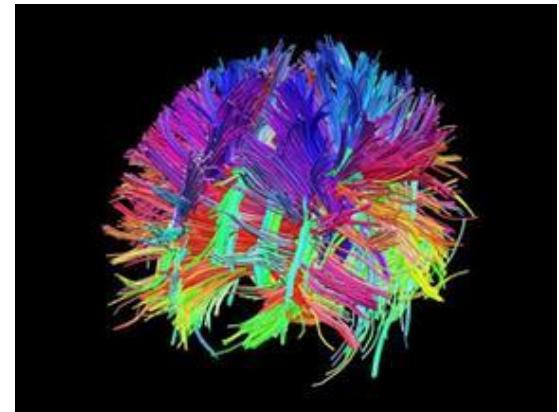


# 美国BRAIN计划

- 2014财年**为脑研究计划拨款**1.1亿美元**,由**NIH、国防部高级研究项目局**(the Defense Advanced Research Projects Agency, DARPA)、**国家科学基金会**(the National Science Foundation, NSF)实施。
  - NIH 将投入约4000万美元,NSF将提供2000万美元,用于开发能感知并记录神经网络活动的分子探针,并通过大数据技术增进对思维、情感、记忆等活动的理解。
  - DARPA 计划投入5000万美元开发一套新的工具来捕获和处理神经元和突触的动态活动,建立相应的信息处理系统和修复机制,用于改进战后患有创伤后应激障碍、脑损伤和记忆丧失的军人的诊断和治疗。

# 美国人脑连接组计划(HCP)

- 简介：**人类连接组项目（Human Connectome Project）是美国国立卫生院NIH 2009年开始资助的一个5年项目，由华盛顿大学、哈佛、麻省总医院、加州大学等单位牵头。
- 主要目标：**使用不同的脑成像技术（主要是静息态功能磁共振，弥散磁共振成像，EEG、MEG等作为补充），在毫米尺度绘制出不同活体人脑功能、结构“图谱”。
- 意义：**一旦绘制出毫米尺度的大脑结构、功能图，就可以进一步研究神经环路的构造，大脑随发育、年龄增长的变化，大脑的网络属性，神经/精神疾病的根源；还可以研究大脑多大程度上由基因决定，以及不同的大脑功能/结构和行为的关系。



# 韩国脑计划

- 韩国2012年成立了韩国脑研究所，从基础神经科学、医学神经科学、认知神经科学到神经工程，开展全面研究，每年投资50-70万美金 / PI。



# 日本脑计划

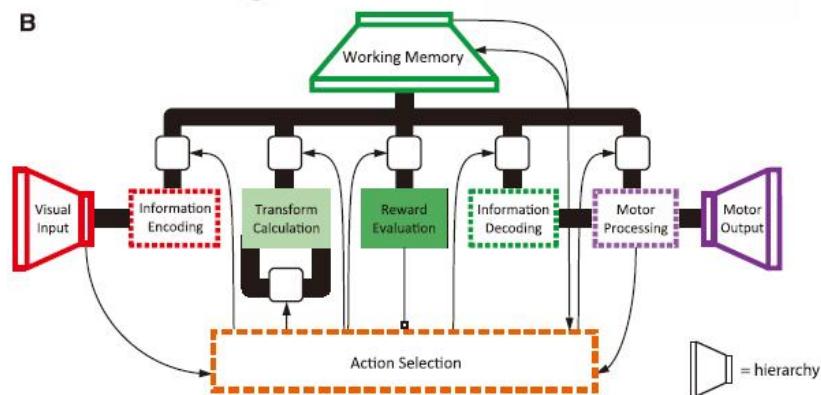
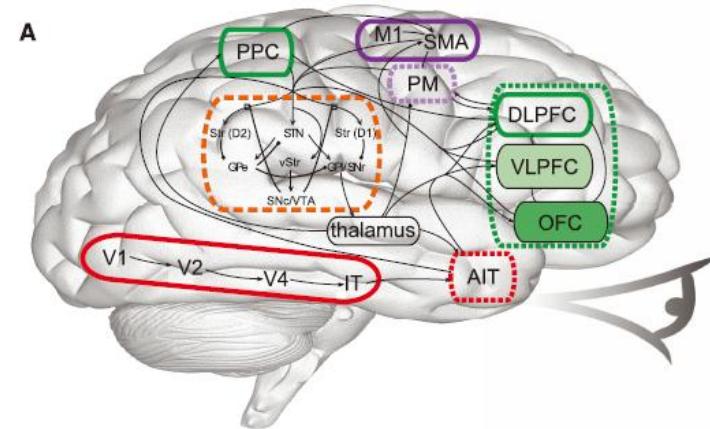
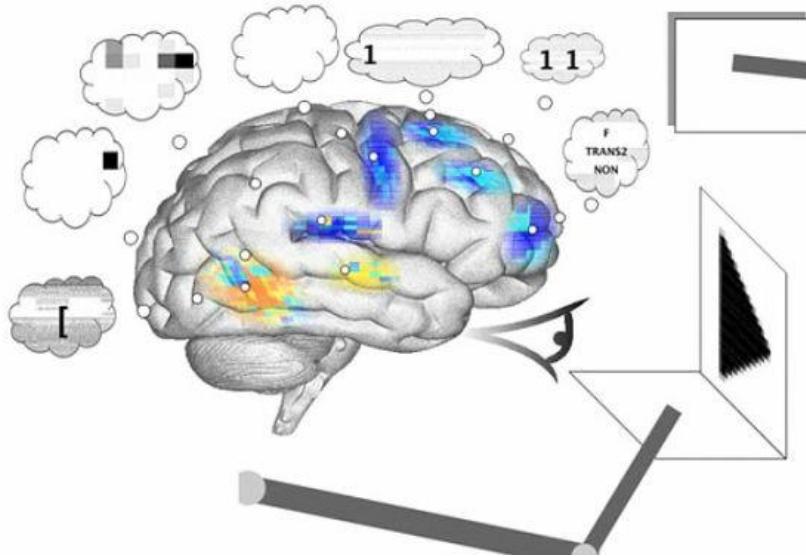
- 1997年7月，日本出台了一个被称为《脑科学时代》的超大型综合计划。这个计划将从1997年开始实施,为期20年，每年投入1000亿日元。它的主导目标和核心内容是，“了解脑”(揭示脑机能)、“保护脑”(克服脑疾患)和“创造脑”(开发人工智能)。
- 2013年6月6日，日本宣布准备利用10年时间开展研究，弄清灵长类动物脑活动的全貌。

# 加拿大脑计划

- 2013年3月加拿大安大略省政府宣布将于未来5年投资1亿加元资助有关疾病的脑科学研究,以维持安大略省在科研与创新领域的领导地位。这一计划将对安大略省的神经退行性疾病、抑郁症、脑瘫、自闭症及癫痫等神经系统疾病的研究产生深远影响,同时促进其他组织和个人资助相关疾病的脑研究。

# 加拿大滑铁卢大学SPAUN项目

•**项目简介：** SPAUN系统由由250万个模拟神经元组成，能执行多种不同类型的任务：文本识别、图像识别、记忆、计数、问答等。该项目通过脑区级别的模拟、不同脑区功能之间的协同控制，初步实现了大规模脑模拟系统。



# 中国的脑科学的研究

•2008年，由国家自然基金委启动了重大研究计划“视听觉信息的认知计算”，历时8年，投资1.5亿；

—科学目标：借鉴人类的认知机理和相关数学的最新研究成果，建立新的计算模型和方法，从而大幅度提高计算机对这类信息的理解能力与处理效率，推动信息科学的快速发展，为国民经济和社会发展做出重大贡献。

—科学问题：视听觉信息协同计算、自然语言（汉语）理解以及与视听觉认知相关的脑—机接口；集成上述相关研究成果，研制具有自然环境感知与智能行为决策能力的无人驾驶车辆验证平台。

# 中国的脑科学的研究

•2011年，由国家自然基金委启动了重大研究计划“情感和记忆的神经环路基础”，历时8年，投资2亿；

—科学目标：本重大研究计划以情感和记忆神经环路为主要研究对象，在多模态、多尺度水平探讨情感和记忆相关的神经环路关键节点和路径及其与重大神经精神疾病特定临床表型之间的关系，揭示神经环路在重大神经精神疾病发生发展中的变化规律，为深入理解神经精神疾病的发病机制，发现新的预防、诊断和治疗手段提供科学依据，为提高我国国民的心理健康水平做出贡献。

—科学问题：围绕情感和记忆的神经环路基础这一核心科学问题，从多层次水平探讨情感与记忆的神经环路，相互作用的机制，以及遗传和环境因素对其调节机制。

# 中国的脑科学的研究

- 2012年，中科院启动中科院战略性先导科技专项（B类）“脑功能联结图谱，历时5年，投资2.5亿。
  - 科学目标：力求完整地描述在正常生理状态和生病状态下，大脑在承担感觉、情绪，学习记忆，决策等重要功能时，各脑区特殊种类神经细胞群之间的连接构造和运作机制，以绘制一张完整的大脑活动图谱。

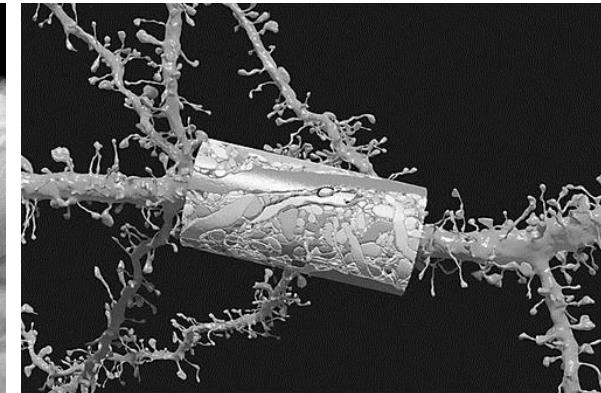
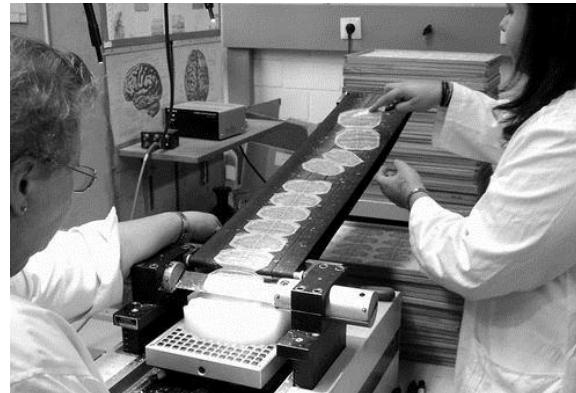
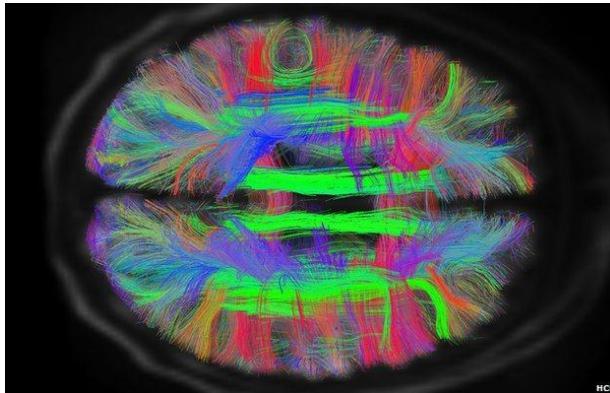


# 准确绘制脑图谱（2014年10大突破性技术之一）

(1) 基于DTI等技术，美国人脑连接组研究计划(HCP)致力于在毫米尺度刻画人脑结构图，目前已对外公布来自**68位健康成人志愿者的脑部扫描图像以及个体性格、认知能力、情感特征和感知功能等行为信息**，数据量达到了两万亿字节(2TB)。

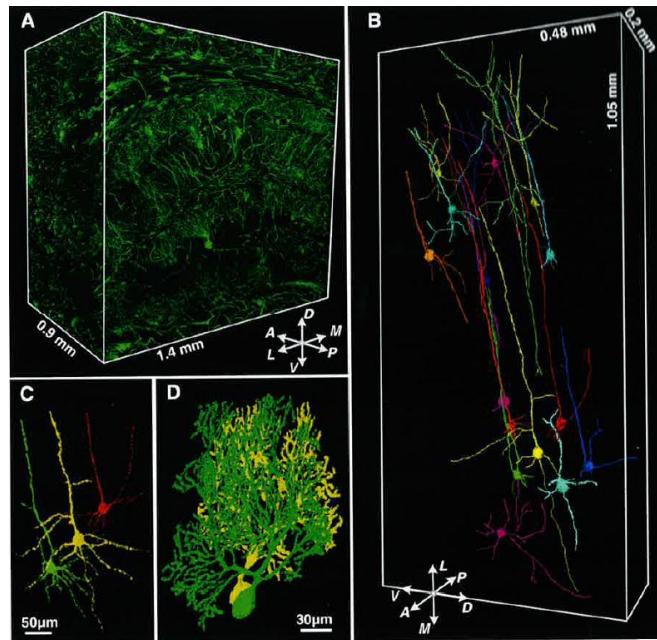
(2) 历经10年的“大脑”(BigBrain)项目，通过对一名65岁妇女的大脑样本进行切片研究和分析，制作出迄今为止最详细的完整三维人脑图，**该“大脑”的分辨率为20微米**。

(3) 美国哈佛大学神经学家将老鼠大脑其中一部分类似圆柱体的组织(**小鼠大脑的十亿分之一**)以史无前例的精细度呈现出来：**680个神经纤维，79个树突，774个突触**。

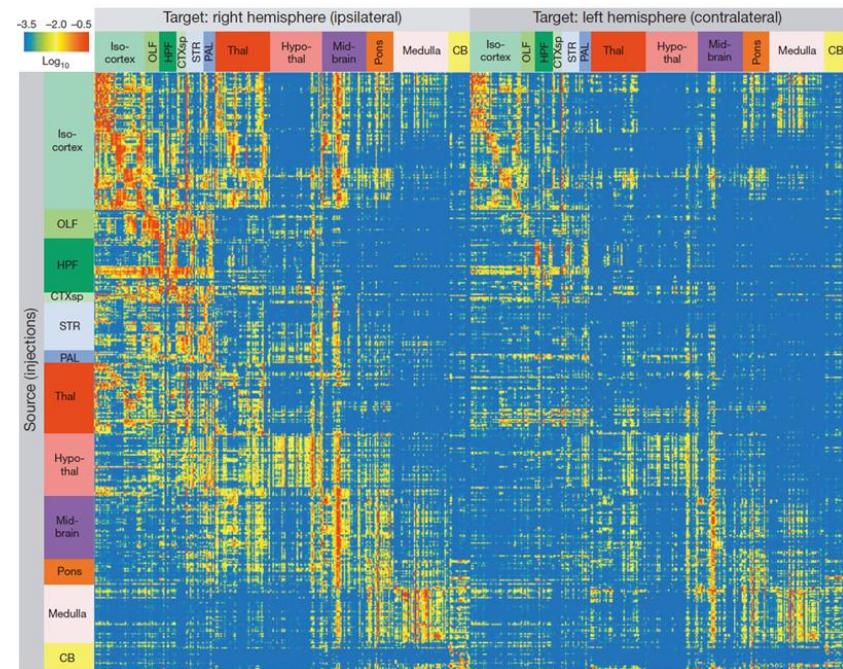


# 准确绘制脑图谱（2014年10大突破性技术之一）

- (4) 华中科技大学，骆清铭研究组发明并研制了一台显微光学切片层析成像系统，使用研制的系统，对制备好的鼠脑为样本，全自动连续242小时进行了数据采集，共获得15380层像素分辨率为 $0.3 \times 0.3$ 微米的冠状断面图像，实现了突起水平的小鼠全脑结构成像。
- (5) 艾伦研究所提供了一个小鼠大脑连接图谱，此图谱是第一个哺乳动物全脑神经元连接图谱。这份详细图谱是迄今为止最全面的脊椎动物大脑连接图谱。



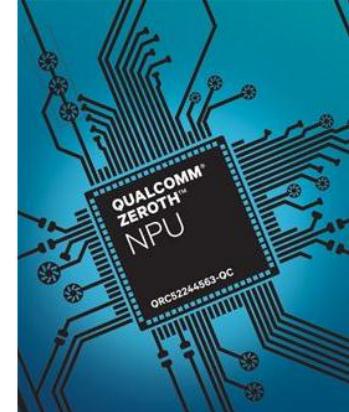
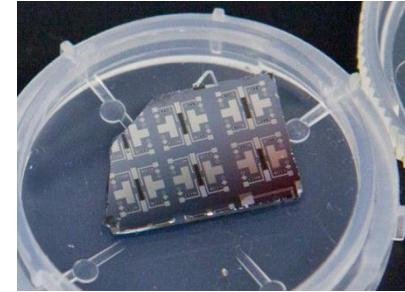
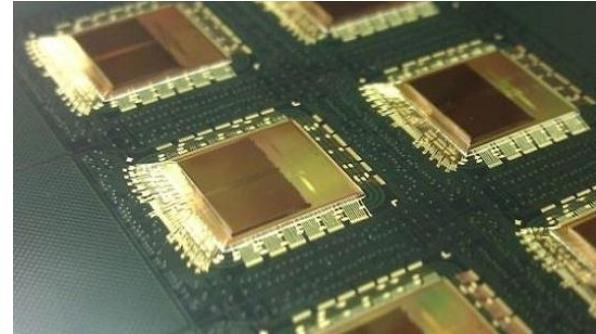
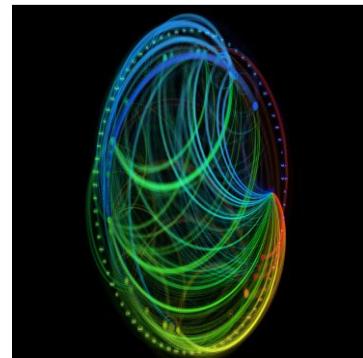
li et,al 2010



Seung et,al 2014

# 神经形态芯片（2014年10大突破性技术之一）

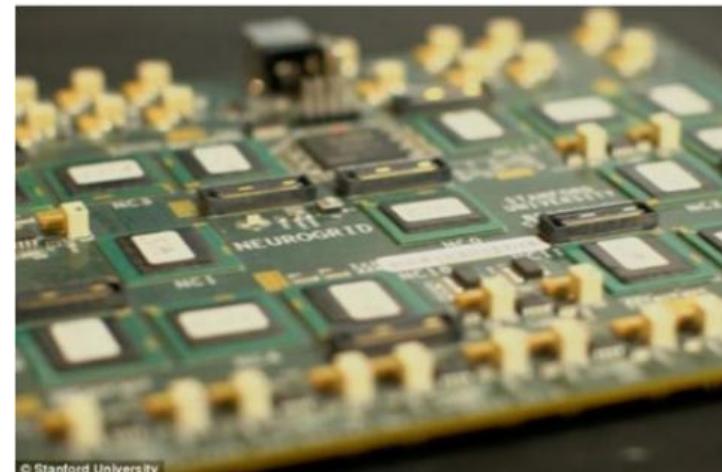
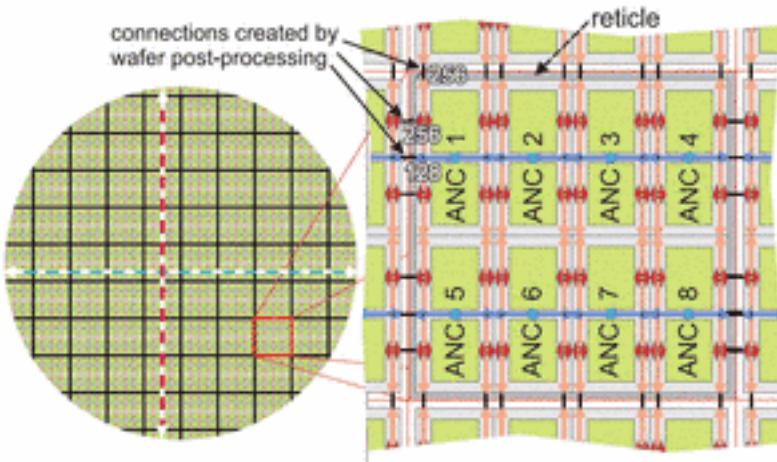
- (1) IBM的“神经形态自适应塑料可微缩电子系统（SyNAPSE）”项目，其从人脑的功能、省电性及紧凑性获得灵感，最新的SyNAPSE芯片集成了256个数字神经元，每个神经元配备1024条突触回路，2019年IBM将会利用88万CPU，研制出与人脑速度相当的模拟人脑系统；
- (2) 英国曼彻斯特大学的SpiNNaker项目通过Arm芯片及神经元放电模式构建类脑计算硬件平台；
- (3) 2013年，美哈佛大学研制出首个模拟人类学习能力的新型晶体管；
- (4) 高通推出神经形态处理芯片，它可以模拟人脑在学习过程产生的各种电荷变化，并最终有望让这些芯片达到儿童的智能水准，以此为基点未来向智能手机、平板和PC领域发展，朝人工智能迈进；



# 神经形态芯片（2014年10大突破性技术之一）

(5) 德国海德堡大学基尔霍夫物理研究所主导的“大脑规模 (BrainScales)”计划的目标是研制出逻辑芯片来模拟神经元和突触的行为，研制出的“高输入模拟神经网络 (HICANN)”能模拟神经元之间的相互作用，目前，HICANN系统能模拟512个神经元的活动，每个神经元配备224个突回路；

(6) 2014年，斯坦福大学研制的新型电路板Neurogrid，采用16个定制的Neurocore芯片，每块可模拟65536个神经元，运算速度可达到当前电脑的9000倍，能耗只有模拟100万个神经元细胞的个人电脑的大约十万分之一



# 总结

- 子空间分析
- 流形学习
- 深度学习
- 人脑工程

祝大家学业顺利！  
谢谢！